

IDENTIFIKASI JENIS MANGROVE MENGGUNAKAN

FASTER REGION CONVOLUTIONAL NEURAL

NETWORK (FASTER R-CNN)

(Studi Kasus: Pulau Bintan)



Skripsi

Untuk memenuhi syarat memperoleh Derajat

Sarjana Teknik (S.T.)

Oleh:

MUHAMAD NUR SYAMI

NIM 2101020005

PROGRAM STUDI TEKNIK INFORMATIKA

JURUSAN TEKNIK ELEKTRO DAN INFORMATIKA

FAKULTAS TEKNIK DAN TEKNOLOGI KEMARITIMAN

UNIVERSITAS MARITIM RAJA ALI HAJI

TANJUNGPINANG

2025

**IDENTIFIKASI JENIS MANGROVE MENGGUNAKAN
FASTER REGION CONVOLUTIONAL NEURAL
NETWORK (FASTER R-CNN)**

(Studi Kasus: Pulau Bintan)



Skripsi

Untuk memenuhi syarat memperoleh Derajat

Sarjana Teknik (S.T.)

Oleh:

MUHAMAD NUR SYAMI

NIM 2101020005

Telah mengetahui dan disetujui oleh:

Pembimbing I,

Nola Ritha, S.T., M.Cs.
NIP. 199011142019032016

Pembimbing II,

Dr. Dony Apdillah, S.Pi., M.Si.
NIPPK. 19760222201211004

HALAMAN PENGESAHAN

Judul Skripsi : Identifikasi Jenis Mangrove menggunakan
Faster Region Convolutional Neural Network
(*Faster R-CNN*) (Studi Kasus: Pulau Bintan)

Nama Mahasiswa : Muhamad Nur Syami

NIM : 2101020005

Jurusan : Teknik Elektro dan Informatika

Program Studi : Teknik Informatika

Telah dipertahankan di depan Dewan Penguji dan dinyatakan lulus
pada tanggal 26 Juni 2025

Susunan Tim Pembimbing dan Penguji

Jabatan	Nama Dosen	Tanda Tangan	Tanggal
Pembimbing I	: Nola Ritha, S.T., M.Cs.		1/7/25
Pembimbing II	: Dr. Dony Apdillah, S.Pi., M.Si.		1/7/25
Ketua Penguji	: Tekad Matulatan, S.Sos., S.Kom., M.Inf.Tech.		1/7/25
Anggota Penguji I	: Marisha Pertiwi, S.Tr.Kom., M.Kom		1/7/25
Anggota Penguji II	: Nolan Efranda, M.Kom		1/7/25

Tanjungpinang, Juli 2025
Universitas Maritim Raja Ali Haji
Dekan Fakultas Teknik dan Teknologi Kemaritiman



PERNYATAAN ORISINALITAS

Dengan ini menyatakan bahwa skripsi saya yang berjudul Identifikasi Jenis Mangrove Menggunakan *Faster Region Convolutional Neural Network (Faster R-CNN)* (Studi Kasus: Pulau Bintan) adalah benar karya saya dengan arahan dari komisi pembimbing dan belum diajukan dalam bentuk apa pun kepada perguruan tinggi mana pun. Sumber informasi yang berasal atau dikutip dari karya yang diterbitkan maupun tidak diterbitkan dari penulis lain telah disebutkan dalam teks dan dicantumkan dalam Daftar Pustaka di bagian akhir skripsi ini.

Jika kemudian hari ternyata terbukti pernyataan saya ini tidak benar dan melanggar peraturan yang sah dalam karya tulis dan hak intelektual maka saya bersedia ijazah yang telah saya terima untuk ditarik kembali oleh Universitas Maritim Raja Ali Haji.

Tanjungpinang, 26 Juni 2025




L0FAMX356905399

Muhamad Nur Syami)

HALAMAN PERSEMBAHAN

Dengan segenap rasa syukur, kerendahan hati dan sebagai bentuk penghargaan serta terima kasih dan perhormatan sebesar-besarnya, saya mempersembahkan karya skripsi ini kepada :

1. Allah Subhanahu Wata'ala, yang telah memberikan segala bentuk nikmat, rezeki, kesehatan serta kesempatan yang luar biasa kepada saya sehingga dapat menyelesaikan tahap sarjana ini hingga akhir.
2. Kedua orang tua yang saya sayangi dan banggakan, Ibu Surati dan Bapak Anizar yang selalu berjasa melebihi siapapun dan dalam hal apapun. Serta kakak perempuan saya Nurbaiti dan adik perempuan saya Nurjanah Afrilia Putri yang selalu menjadi penyemangat dalam menempuh dunia pendidikan.
3. Ibu Nola Ritha, S.T., M.Cs dan Bapak Dr. Donny Apdillah, S.Pi., M.Si sebagai dosen pembimbing yang telah berbagi ilmu, memberikan arahan, dukungan, serta motivasi selama proses penulisan dan penyelesaian skripsi ini.
4. Para dosen khususnya Bu Nurul Hayaty, S.T., M.Cs, staff akademik terutama Pak Rusli dan pihak kampus lainnya, yang telah memberikan ilmu, bantuan teknis, serta inspirasi selama masa pendidikan.
5. Kepada Cucuts sigma : Sahra Fatimah Yasir, Silvia Indah Maharani, Yoga Syahputra, Alhuwayrist Royhan Apriyanto, Winona Lusiana Sitorus, Sevia Anggreini Simanjuntak, Amanda Dwi Mulyani yang telah membantu, menemani dalam menyelesaikan karya tulis ini.
6. Kepada O.Riastanjung, S.T yang merupakan panutan dalam kehidupan penulis sebagai programmer yang hebat serta telah banyak membantu penulis dalam proses perkembangan dan karir penulis dalam bidang programmer serta telah membantu skripsi penulis.
7. Kepada Ghora Laziola, S.T, Syahri Ramadhan, S.T, Trinanda, S.T yang telah membantu dan membimbing penulis dalam pengambilan data penulis, serta memberikan wawasan yang luas dalam berbagai hal.

- 
8. Kepada Arifian Saputra, S.T, Siska Anggraeni, S.T, Sha Nia Siahaan, S.T, Musliha, S.T, Mia Al Fiani, S.T, Leonardo Tegarsuan, S.T, Agsanshina Raka Syakti, S.T dan teman-teman Teknik Informatika angkatan 20 yang tidak bisa disebutkan satu persatu yang selalu mengajar dan membimbing penulis.
 9. Kepada Teman penulis Farel Putra Albana yang telah banyak membantu dalam karya tulis ini.
 10. Kepada Teman terdekat : Hamdan, Vinandra Adam, M Rizki Fachriza Bailey, Mahadi Dwi Nugraha dan teman-teman Teknik Informatika Angkatan 21 yang telah memberikan motivasi, dukungan serta menemani proses bersama pada masa perkuliahan.
 11. Kepada Agustian Damar Permana, Rizky Hidayatullah, Surya Dwi Aditya, Wahyu Siregar yang senantiasa mendukung dan memotivasi penulis dalam menyelesaikan skripsi
 12. Seluruh pihak yang telah membantu dan menyelesaikan pendidikan saya yang tidak bisa penulis sebutkan satu persatu.
 13. Terakhir, untuk Muhamad Nur Syami yaitu penulis sendiri yang telah tetap semangat dan terus maju hingga menyelesaikan karya tulis ini.

HALAMAN MOTO

“Sungguh, sholat itu adalah kewajiban yang ditentukan waktunya atas orang orang yang beriman”

(Q.S. An-Nisa : 103)

“Ketahuilah Yang Allah tawarkan itu mahal, yang Allah tawarkan itu Surga”

“Jika dirimu terlahir dari keluarga yang tidak memiliki privilege, pastikan bahwa keluarga yang kamu bangun kelak harus memiliki privilege itu”

“Semua orang capek, semua orang lelah, ada yang berisik dan ada juga yang diam, ngeluh boleh, menyerah jangan”

“Manfaatkan waktu rajin mu sebelum waktu malas mu datang,
Manfaatkan kesehatan mu sebelum kesakitan itu datang,

Manfaatkan waktu luang mu, sebelum waktu sibuk mu datang,

Manfaatkan kehidupan mu sebelum kematian mu itu datang,

Manfaatkan waktu kebersamaanmu sebelum perpisahan itu datang”

“Jadilah orang yang bermanfaat bagi semua orang,
bukan menyenangkan semua orang“

(Muhamad Nur Syami)

KATA PENGANTAR

KATA PENGANTAR

Segala puji dan syukur atas kehadiran Allah Subhanahu Wa Ta'ala atas limpahan rahmat, karunia, dan ridho-Nya sehingga penulis dapat menyelesaikan skripsi yang berjudul “Identifikasi Jenis Mangrove menggunakan *Faster Region Convolutional Neural Network (Faster R-CNN)* (Studi Kasus : Pulau Bintan)”. Skripsi ini disusun sebagai salah satu syarat untuk memperoleh gelar sarjana pada Program Studi Teknik Informatika, Jurusan Teknik Elektor dan Informatika, Fakultas Teknik dan Teknologi Kemaritiman, Universitas Maritim Raja Ali Haji (UMRAH).

Selama penyusunan skripsi ini, penulis menerima banyak doa, dukungan bimbingan dan bantuan dari berbagai pihak. Dengan rasa syukur, penulis mengucapkan terima kasih sebesar-besarnya kepada:

1. Allah Subhanahu Wata'ala, atas segala rahmat, nikmat, dan ridho-Nya yang senantiasa melimpahi sehingga penulis dapat menyelesaikan skripsi ini.
2. Kedua orang tua dan keluarga yang selalu memberikan dukungan dan semangat, serta doa tanpa henti bagi keberhasilan penulis.
3. Bapak dan Ibu Dosen Pembimbingan, yang telah memberikan bimbingan, arahan, masukan, serta solusi kepada penulis selama proses penyusunan skripsi ini.
4. Rekan-rekan seperjuangan Teknik Informatika angkatan 2021 dan 2020 serta seluruh pihak yang telah membantu proses penyusunan skripsi ini.

Penulis menyadari bahwa skripsi ini belum sempurna, sehingga kritik dan saran membangun sangat diharapkan. Semoga skripsi ini bermanfaat dan berkontribusi dalam pengembangan ilmu pengetahuan.

Tanjungpinang, 26 Juni 2025




(Muhamad Nur Syami)

DAFTAR ISI

HALAMAN JUDUL.....	i
HALAMAN PENGESAHAN.....	iii
PERNYATAAN ORISINALITAS	iv
HALAMAN PERSEMBAHAN.....	v
HALAMAN MOTO.....	vii
KATA PENGANTAR	viii
DAFTAR ISI.....	ix
DAFTAR TABEL.....	xii
DAFTAR GAMBAR	xiii
GLOSARIUM.....	xv
ABSTRAK	xvi
ABSTRACT	xvii
BAB I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Perumusan Masalah	4
1.3 Batasan Masalah.....	5
1.4 Tujuan Penelitian	5
1.5 Manfaat Penelitian	6
1.6 Sistematika Penulisan.....	6
BAB II KAJIAN LITERATUR	8
2.1 Tinjauan Pustaka	8
2.2 Landasan Teori.....	11
2.2.1 Mangrove	11
2.2.2 Macam-macam Mangrove di Pulau Bintan.....	11
2.2.3 <i>Deep Learning</i>	17
2.2.4 <i>Convolutional Neural Network (CNN)</i>	18
2.2.5 Arsitektur ResNet-50.....	25
2.2.6 <i>Feature Pyramid Network (FPN)</i>	26
2.2.7 <i>Region Proposal Network (RPN)</i>	27
2.2.8 <i>Region of Interest Pooling Layer (ROI Pooling)</i>	28

2.2.9	<i>Intersection over Union (IoU)</i>	30
2.2.10	<i>Faster Region Convolutional Neural Network</i>	31
2.2.11	<i>Average Precision (AP)</i>	34
2.2.12	<i>Mean Average Precision (mAP)</i>	34
2.2.13	Python.....	35
2.2.14	Transfer Learning	35
2.2.15	Parameter yang digunakan	36
BAB III	METODE PENELITIAN.....	38
3.1	Waktu Penelitian.....	38
3.2	Jenis Penelitian.....	38
3.3	Instrumen Penelitian.....	38
3.4	Prosedur Penelitian.....	39
3.5	Studi Pustaka	40
3.6	Pengumpulan Data	41
3.7	Analisis dan Perancangan	42
3.7.1	Analisis data	42
3.7.2	Perancangan Algoritma <i>Faster R-CNN</i> dan <i>Backbone ResNet 50 FPN</i>	44
3.7.3	Perancangan Aplikasi Mobile Identifikasi Mangrove di Pulau Bintan..	
56		
3.7.4	Rancangan Tampilan <i>User Interface (UI)</i>	59
BAB IV	HASIL DAN PEMBAHASAN	66
4.1	Lingkungan Uji Coba	66
4.2	Pelatihan dan Metrik Evaluasi performa Algoritma Faster R-CNN	67
4.2.1	Pelatihan Algoritma Faster R-CNN <i>Batch size 4</i>	67
4.2.2	Pelatihan Algoritma Faster R-CNN <i>Batch size 8</i>	71
4.2.3	Pelatihan Algoritma Faster RCNN <i>Batch size 16</i>	75
4.2.4	Hasil Keseluruhan Pelatihan Model.....	79
4.3	Pengujian dan Analisis Akurasi Model <i>Faster R-CNN</i>	81
4.3.1	Pengujian Akurasi Pada Dataset <i>One Label</i>	82
4.3.2	Pengujian Akurasi Pada Dataset <i>Multi Label</i>	93
4.3.3	Pengujian Akurasi Pada Dataset Pengaruh Posisi Objek.....	95
4.3.4	Pengujian Akurasi Pada Bukan Jenis Mangrove	97

4.4 Hasil Perancangan Aplikasi Mobile	100
4.4.1 Tampilan Halaman <i>Splash Screen</i>	100
4.4.2 Tampilan Halaman <i>Home</i>	101
4.4.3 Tampilan Ambil Foto.....	102
4.4.4 Tampilan Unggah Gambar.....	103
4.4.5 Tampilan Petunjuk.....	104
4.4.6 Tampilan Validasi Foto	105
4.4.7 Tampilan Hasil Deteksi	106
4.4.8 Tampilan Jenis Mangrove.....	107
4.4.9 Tampilan Detail Jenis Mangrove.....	108
4.4.10 Tampilan <i>Developer</i>	109
BAB V PENUTUP	110
5.1 Kesimpulan	110
5.2 Saran.....	110
DAFTAR PUSTAKA	112
LAMPIRAN	120



DAFTAR TABEL

Tabel 2. 1 Jenis Mangrove Yang Diambil	13
Tabel 3. 1 Distribusi Dataset.....	41
Tabel 3. 2 <i>Kernel 3x3</i>	51
Tabel 4. 1 Spesifikasi Lingkungan Uji Coba	66
Tabel 4. 2 Parameter yang digunakan.....	67
Tabel 4. 3 Nilai AP IoU=0.5 <i>Epoch 30 Batch size 4</i>	70
Tabel 4. 4 Nilai AP IoU=0.5 <i>Epoch 30 Batch size 8</i>	74
Tabel 4. 5 Nilai AP IoU=0.5 <i>Epoch 30 Batch size 16</i>	78
Tabel 4. 6 Hasil Pelatihan Terbaik Pada <i>Batch size 4 Epoch 30</i>	80
Tabel 4. 7 Hasil Pelatihan <i>Batch size 8 Epoch 30</i>	80
Tabel 4. 8 Hasil Pelatihan <i>Batch size 16 Epoch 30</i>	81
Tabel 4. 9 Pengujian Dataset <i>Avicennia Lanata</i>	82
Tabel 4. 10 Pengujian Dataset <i>Lumnitzera liitorea</i>	83
Tabel 4. 11 Pengujian Dataset <i>Sonneratia Alba</i>	84
Tabel 4. 12 Pengujian Dataset <i>Bruguiera gymnorhiza</i>	85
Tabel 4. 13 Pengujian Dataset <i>Rhizophora apiculata</i>	86
Tabel 4. 14 Pengujian Dataset <i>Scyphiphora hydrophyllacea</i>	87
Tabel 4. 15 Pengujian Dataset <i>Rhizophora mucronata</i>	88
Tabel 4. 16 Pengujian Dataset <i>Brugueira cylindrica</i>	89
Tabel 4. 17 Pengujian Dataset <i>Xylocarpus granatum</i>	90
Tabel 4. 18 Hasil Keseluruhan Pengujian <i>One Label</i>	92
Tabel 4. 19 Pengujian Dataset Bukan Jenis Mangrove Gambar <i>Random</i>	97
Tabel 4. 20 Pengujian Dataset Bukan Jenis Mangrove Objek Dominan Hijau	98

DAFTAR GAMBAR

Gambar 2. 1 Arsitektur <i>Convolutional Neural Network</i>	18
Gambar 2. 2 <i>Convolutional Layer</i>	20
Gambar 2. 3 Proses Perhitungan ReLU	21
Gambar 2. 4 <i>Pooling Layer</i>	23
Gambar 2. 5 <i>Flatten</i>	24
Gambar 2. 6 <i>Fully Connected</i>	25
Gambar 2. 7 Arsitektur ResNet-50.....	26
Gambar 2. 8 Proses <i>ROI Layer</i>	29
Gambar 2. 9 <i>Intersection over Union</i>	30
Gambar 2. 10 Arsitektur Faster R-CNN	31
Gambar 3. 1 Metode Penelitian.....	39
Gambar 3. 2 Flowchart <i>Labeling</i> Kelas Menggunakan Roboflow	43
Gambar 3. 3 Rancangan Arsitektur ResNet-50.....	45
Gambar 3. 4 Rancangan Faster R-CNN dengan ResNet-50 FPN	48
Gambar 3. 5 Flowchart <i>Training Model</i>	49
Gambar 3. 6 <i>Sample</i> Citra Input.....	51
Gambar 3. 7 Posisi 1 <i>Channel Red</i>	52
Gambar 3. 8 Hasil Konvolusi <i>Channel Red, Green dan Blue</i>	53
Gambar 3. 9 Hasil Penjumlahan <i>Channel RGB</i>	54
Gambar 3. 10 Hasil ReLU.....	54
Gambar 3. 11 Flowchart Perancangan Sistem untuk Identifikasi Jenis Mangrove	57
Gambar 3. 12 <i>User Interface</i> Halaman <i>Splash Screen</i>	59
Gambar 3. 13 <i>User Interface</i> Halaman <i>Home Screen</i>	59
Gambar 3. 14 <i>User Interface</i> Halaman Ambil Foto.....	60
Gambar 3. 15 <i>User Interface</i> Halaman Unggah Gambar.....	61
Gambar 3. 16 <i>User Interface</i> Halaman <i>Pop Up Aturan</i>	61
Gambar 3. 17 <i>User Interface</i> Halaman Validasi Gambar	62
Gambar 3. 18 <i>User Interface</i> Halaman Ouput Prediksi	63
Gambar 3. 19 <i>User Interface</i> Halaman Jenis Mangrove.....	63
Gambar 3. 20 <i>User Interface</i> Halaman Detail Jenis Mangrove	64

Gambar 3. 21 <i>User Interface</i> Halaman <i>Developer</i>	65
Gambar 4. 1 <i>Training Loss Epoch 30 Batch size 4</i>	68
Gambar 4. 2 Grafik Validasi mAP IoU=0.5:0.95 <i>Epoch 30 Batch size 4</i>	69
Gambar 4. 3 Grafik Validasi AP IoU=0.50 <i>Epoch 30 Batch size 4</i>	71
Gambar 4. 4 <i>Training Loss Epoch 30 Batch size 8</i>	72
Gambar 4. 5 Grafik Validasi mAP IoU=0.5:0.95 <i>Epoch 30 Batch size 8</i>	73
Gambar 4. 6 Grafik Validasi AP IoU=0.50 <i>Epoch 30 Batch size 8</i>	75
Gambar 4. 7 <i>Training Loss Epoch 30 Batch size 16</i>	76
Gambar 4. 8 Grafik Validasi mAP IoU=0.5:0.95 <i>Epoch 30 Batch size 16</i>	77
Gambar 4. 9 Grafik Validasi AP IoU=0.50 <i>Epoch 30 Batch size 16</i>	78
Gambar 4. 10 Pengujian Dataset <i>Multi Label</i>	94
Gambar 4. 11 Pengaruh Posisi Objek	96
Gambar 4. 12 Pengujian Dataset Bukan Mangrove	99
Gambar 4. 13 Tampilan <i>Splash Screen</i>	100
Gambar 4. 14 Tampilan Halaman <i>Home</i>	101
Gambar 4. 15 Tampilan Halaman Ambil Foto.....	102
Gambar 4. 16 Tampilan Halaman Unggah Gambar.....	103
Gambar 4. 17 Tampilan Halaman Aturan	104
Gambar 4. 18 Tampilan Halaman Validasi Gambar	105
Gambar 4. 19 Tampilan Halaman Hasil Deteksi	106
Gambar 4. 20 Tampilan Halaman Jenis Mangrove.....	107
Gambar 4. 21 Tampilan Halaman Detail Jenis Mangrove	108
Gambar 4. 22 Tampilan Halaman <i>Developer</i>	109

GLOSARIUM

<i>AP</i>	Metrik Evaluasi untuk mengukur nilai rata-rata presisi yang dihitung untuk satu kelas objek dalam deteksi
<i>Batch size</i>	Parameter yang menentukan berapa banyak data yang diproses sekaligus sebelum model diperbarui selama pelatihan
<i>Epochs</i>	Jumlah pengulangan dalam proses pelatihan model yang melibatkan seluruh data perlatihan
<i>FPN</i>	Metode untuk meningkatkan kemampuan model dalam mendeteksi objek dengan menggabungkan fitur dari berbagai skala resolusi
<i>Faster R-CNN</i>	Algoritma deteksi objek yang menggunakan jaringan konvolusi untuk menemukan dan mengklasifikasikan objek dalam gambar
<i>Learning rate</i>	Parameter yang mengontrol seberapa besar perubahan bobot model pada setiap iterasi pelatihan
<i>Mangrove</i>	Jenis vegetasi yang tumbuh di kawasan pesisir dan dipengaruhi oleh pasang surut air laut. Jenis ini dapat ditemukan di daerah tropis dan subtropis di seluruh dunia
<i>mAP</i>	Metriks evaluasi untuk mengukur keseluruhan performa model dalam mendeteksi objek dengan benar.
<i>Optimizer SGD</i>	Algoritma optimasi yang digunakan untuk memperbarui bobot model berdasarkan gradien dari fungsi <i>loss</i> .

ABSTRAK


Syami, Muhamad Nur. 2025. *Identifikasi Jenis Mangrove Menggunakan Faster Region Convolutional Neural Network (Faster R-CNN): Studi kasus di Pulau Bintan*, Skripsi. Tanjungpinang: Jurusan Teknik Elektro dan Informatika, Program Studi Teknik Informatika, Fakultas Teknik dan Informatika, Universitas Maritim Raja Ali Haji, Pembimbing 1: Nola Ritha S.T., M.Cs. Pembimbing II: Dr. Dony Apdillah, S.Pi., M.Cs.

Penelitian ini bertujuan untuk mengukur performa akurasi model menggunakan algoritma *Faster R-CNN* dengan arsitektur ResNet-50 FPN sebagai *backbone* dalam mengidentifikasi 9 jenis mangrove di Pulau Bintan. Proses pelatihan yang dilakukan pada model dengan membandingkan metrik evaluasi AP dan mAP pada *epoch* 30 diberbagai *batch size* seperti 4, 8 dan 16 dengan paramater yang digunakan yaitu *learning rate* sebesar 0,01, *momentum* sebesar 0,9, *weight decay* sebesar 0,0005 dan *optimizer* SGD. Hasil eksperimen menghasilkan bahwa *batch size* 4 memiliki nilai metrik evaluasi terbaik dari berbagai *batch size* yang dilakukan pada proses pelatihan dengan nilai mAP sebesar 62,59% dan nilai AP untuk kelas *Avicennia Lanata* sebesar 95,61%, *Bruguiera cylindrica* sebesar 82,27%, *Bruguiera gymnorhiza* sebesar 97,72%, *Lumnitzera liitorea* sebesar 96,46%, *Rhizophora apiculata* sebesar 95,42%, *Rhizophora mucronata* sebesar 93,19%, *Scyphiphora hydrophyllacea* sebesar 97,87%, *Sonneratia Alba* sebesar 99,00%, *Xylocarpus granatum* sebesar 89,99%. Hasil ini menunjukkan bahwa model *Faster R-CNN* dengan *backbone* ResNet-50 FPN mampu mendeteksi dan mengklasifikasikan jenis mangrove di Pulau Bintan sehingga dapat membantu dalam peningkatan pemahaman keberagaman mangrove sebagai upaya pelestarian ekosistem mangrove diwilayah tersebut.

Kata kunci : *Faster R-CNN, Mangrove, mAP, AP, FPN*

ABSTRACT

Syami, Muhamad Nur. 2025. Mangrove Type Identification Using Faster Region Convolutional Neural Network (Faster R-CNN): Case study in Bintan Island, Skirpsi. Tanjungpinang: Department of Electrical Engineering and Informatics, Informatics Engineering Study Program, Faculty of Engineering and Informatics, Raja Ali Haji Maritime University, Advisor I: Nola Ritha S.T., M.Cs. Advisor II: Dr. Dony Apdillah, S.Pi., M.Cs.



This study aims to measure the performance of model accuracy using the Faster R-CNN algorithm with ResNet-50 FPN architecture as a backbone in identifying 9 types of mangroves on Bintan Island. The training process carried out on the model by comparing the AP and mAP evaluation metrics at epoch 30 in various batch sizes such as 4, 8 and 16 with the parameters used, namely learning rate of 0.01, momentum of 0.9, weight decay of 0.0005 and SGD optimizer. The experimental results show that batch size 4 has the best evaluation metric value from various batch sizes performed in the training process with an mAP value of 62.59% and AP values for Avicennia Lanata classes of 95.61%, Bruguiera cylindrica of 82.27%, Bruguiera gymnorhiza by 97.72%, Lumnitzera liitorea by 96.46%, Rhizophora apiculata by 95.42%, Rhizophora mucronata by 93.19%, Scyphiphora hydrophyllacea by 97.87%, Sonneratia Alba by 99.00%, Xylocarpus granatum by 89.99%. These results show that the Faster R-CNN model with the ResNet-50 FPN backbone is able to detect and classify mangrove species on Bintan Island so that it can help in improving understanding of mangrove diversity as an effort to preserve mangrove ecosystems in the region.

Keywords : *Faster R-CNN, Mangrove, mAP, AP, FPN*

BAB I

PENDAHULUAN

1.1 Latar Belakang

Indonesia merupakan negara kepulauan yang terdiri dari 17.508 pulau dan memiliki potensi sumber daya laut serta pesisir yang sangat besar (Martuti el al., 2019 dalam Maryam et al., 2024). Wilayah pesisir Indonesia sebagian besar didominasi oleh ekosistem mangrove yang berperan penting dalam menjaga keseimbangan lingkungan serta keanekaragaman hayati (Syamsuddin et al., 2019 dalam Maryam et al., 2024). Berdasarkan Peta Mangrove Nasional yang diterbitkan oleh Kementerian Lingkungan Hidup dan Kehutanan, luas ekosistem mangrove di Indonesia saat ini mencapai 3.640.076 hektar, dengan 2.661.281 hektar berada dalam kawasan lindung dan 702.779 hektar diluar kawasan (Kementerian Lingkungan Hidup dan Kehutanan, 2021). Salah satu wilayah yang memiliki ekosistem mangrove adalah Pulau Bintan.

Mangrove memiliki peran krusial dalam menjaga keseimbangan ekosistem pesisir, terutama sebagai habitat bagi berbagai biota laut serta sebagai penyedia oksigen bagi lingkungan sekitarnya (Liubana et al., 2022). Ekosistem mangrove memiliki fungsi yang kompleks, mencakup aspek fisik, biologis dan ekonomi. Secara fisik, mangrove berperan dalam mencegah abrasi, melindungi pesisir dari terpaan angin kencang, serta mengendalikan laju masuknya air laut. Selain itu mangrove juga berfungsi sebagai pelindung kawasan dibelakangnya dari dampak gelombang, angin kencang dan potensi bencana tsunami, sekaligus menjaga stabilitas garis pantai dari erosi dan abrasi. Dari segi biologis, mangrove menjadi tempat bersarang bagi burung serta habitat alami bagi berbagai jenis biota laut. Sementara itu, secara ekonomi, ekosistem mangrove menyediakan berbagai jenis bahan baku yang dapat dimanfaatkan manusia, seperti sumber pangan, pewarna alami, bahan kosmetik, arang, kayu serta pakan ternak (Maryam et al., 2024).

Keanekaragaman mangrove memiliki banyak jenis yang terdiri dari jenis tumbuhan antara lain *Rhizophora*, *Avicennia*, *Sonneratia*, *Bruguiera*, *Ceriops*, *Lumnitzera* dan lain-lain yang dapat tumbuh subur diwilayah pesisir (Sinabang et al., 2022). Dari penelitian yang dilakukan oleh (Apdillah et al., 2023) dikawasan Sungai Pengudang, Pulau Bintan ditemukan terdapat 11 jenis yang telah teridentifikasi yaitu *Rhizophora mucronata*, *Rhizophora apiculata*, *Bruguiera gymnoriza*, *Xylocarpus granatum*, *Ceriops tagal*, *Avicennia alba*, *Scyphiphora hydrophyllacea*, *Sonneratia Alba*, *Sonneratia marina*, *Nypa fruticans* dan *Pandanus tectorius*. Mengingat keberagaman jenis mangrove yang ada, pemahaman yang lebih mendalam mengenai identifikasi spesies mangrove di Pulau Bintan menjadi hal yang penting untuk dilakukan.

Proses identifikasi jenis mangrove umumnya dilakukan secara langsung di lapangan melalui observasi atau pengamatan terhadap sampel tumbuhan mangrove. Pengamatan ini mencakup analisis morfologi pada berbagai bagian tumbuhan seperti akar, batang, daun, bunga dan buah. Karakteristik morfologi yang diamati kemudian dibandingkan dengan referensi dalam *Panduan Pengenalan Mangrove Indonesia* untuk menentukan jenis spesifik dari mangrove yang diamati (Maryam et al., 2024). Namun, proses ini menghadirkan tantangan tersendiri, terutama karena tidak semua orang memiliki pemahaman yang cukup dalam mencocokan karakteristik morfologi mangrove dengan referensi dalam buku panduan. Tantangan ini semakin kompleks ketika beberapa spesies memiliki kemiripan morfologi yang tinggi atau ditemukan di lingkungan yang serupa. Metode tradisional atau manual dalam mengidentifikasi jenis mangrove berdasarkan morfologi membutuhkan keahlian khusus serta pengalaman yang cukup. Selain itu, hasil identifikasi yang diperoleh dapat bervariasi tergantung pada tingkat pemahaman dan ketelitian individu dalam melakukan pengamatan.

Tantangan dalam proses identifikasi jenis mangrove dapat diatasi dengan menerapkan teknologi kecerdasan buatan, khususnya dalam bidang *computer vision* yang terus berkembang pesat dalam deteksi objek. Teknologi ini memungkinkan sistem untuk mengenali dan mengklasifikasi jenis daun mangrove secara lebih akurat. Salah satu pendekatan yang dapat digunakan adalah *deep learning*, yang merupakan subbidang dari *machine learning* dan telah terbukti efektif dalam pemrosesan citra untuk identifikasi objek.

Metode *Convolutional Neural Network* (CNN) merupakan salah satu pendekatan dalam *deep learning* yang memiliki kemampuan untuk melakukan proses pembelajaran secara mandiri, terutama dalam deteksi objek, ekstraksi fitur, serta klasifikasi pada input berupa citra. Seiring dengan perkembangan teknologi, metode CNN terus mengalami penyempurnaan oleh para peneliti guna meningkatkan efisiensi komputasi serta akurasi model. Salah satu metode yang dikembangkan dari CNN adalah *Faster Region Convolutional Neural Network* (*Faster R-CNN*), yang dapat mendeteksi deteksi objek (Romadhon & Setiyono, 2024).

Penelitian sebelumnya yang dilakukan oleh (Trinanda, 2024) penelitian ini berfokus pada identifikasi jenis mangrove menggunakan *machine learning* serta menyarankan penambahan dataset pelatihan untuk meningkatkan performa model dalam proses identifikasi. Penambahan dataset diharapkan dapat memperkuat kemampuan model dalam mengenali berbagai jenis mangrove dengan lebih akurat. Selain itu, penelitian ini juga merekomendasikan penerapan algoritma *deep learning* untuk meningkatkan generalisasi model dalam mengidentifikasi jenis mangrove secara lebih efektif di lapangan. Sementara itu, penelitian yang dilakukan oleh (Asnur et al., 2023) tentang identifikasi tiga jenis mangrove menggunakan metode *deep learning Convolutional Neural Network* (CNN) hasil penelitian ini menunjukkan bahwa model yang digunakan memperoleh akurasi sebesar 81,25% pada pengujian data.

Penelitian yang dilakukan oleh Pratama et al., (2024) tentang *Convolutional Neural Network* dan *Faster Region Convolutional Neural Network* Untuk Klasifikasi Kualitas Biji Kopi Arabika mendapatkan hasil akurasi sebesar 86% menggunakan metode CNN-VGG16 sementara metode *Faster R-CNN* mencapai akurasi sebesar 93%.

Berdasarkan berbagai penelitian yang telah dijelaskan sebelumnya, penelitian ini akan menggunakan algoritma *Faster R-CNN* dengan *backbone* ResNet-50 FPN dikarenakan ResNet-50 dapat mengatasi masalah *vanishing gradient* yang sering terjadi pada jaringan yang semakin dalam (Nashrullah et al., 2020) serta *Feature Pyramid Network* (FPN) yang merupakan jaringan yang dapat menghasilkan informasi semantik dalam berbagai skala sehingga berguna untuk mendeteksi objek yang kecil hingga besar (Hu & Wang, 2020) untuk mengidentifikasi jenis mangrove di Pulau Bintan berdasarkan karakteristik daun atau bunga. Dataset yang akan digunakan dibagi menjadi 9 kelas mangrove seperti *Avicennia Lanata*, *Bruguiera cylindrica*, *Brugueira gymnorhiza*, *Rhizophora apiculata*, *Scyphiphora hydrophyllacea*, *Lumnitzera liitorea*, *Sonneratia Alba*, *Xylocarpus granatum*, *Rhizophora mucronata*. Penelitian ini diharapkan dapat mengidentifikasi dan mengklasifikasi jenis mangrove dengan lebih akurat serta mengembangkan model yang lebih baik dibandingkan model sebelumnya dengan menerapkan *Faster R-CNN*. Selain itu penelitian ini juga bertujuan untuk memberikan kontribusi yang signifikan bagi masyarakat di Pulau Bintan dengan meningkatkan pemahaman mengenai keanekaragaman jenis mangrove sebagai upaya dalam pelestarian atau konservasi mangrove yang terdapat diwilayah tersebut.

1.2 Perumusan Masalah

Berdasarkan latar belakang penelitian yang telah dijelaskan diatas, maka rumusan masalah penelitian adalah seberapa akurat algoritma *Faster R-CNN* dalam mengidentifikasi jenis mangrove?

1.3 Batasan Masalah

Agar penelitian lebih terarah dan berorientasi pada permasalahan utama serta tidak keluar dari ruang lingkup yang telah ditetapkan, batasan masalah yang dirumuskan adalah sebagai berikut:

1. Dataset yang digunakan dalam penelitian ini berjumlah 5.400 gambar yang diambil disekitar wilayah di Pulau Bintan.
2. Dataset yang digunakan dalam penelitian ini dibagi menjadi 9 kelas mangrove yang tiap kelas sebanyak 600 data yang terdiri dari 300 data daun dan 300 data bunga seperti *Avicennia Lanata*, *Bruguiera cylindrica*, *Brugueira gymnorhiza*, *Rhizophora apiculata*, *Scyphiphora hydrophyllacea*, *Lumnitzera liitorea*, *Sonneratia Alba*, *Xylocarpus granatum*, *Rhizophora mucronata*.
3. Aspek rasio gambar yang digunakan adalah 1:1 dengan seluruh permukaan objek yang terlihat jelas 100%.
4. Jarak pengambilan gambar berkisar antara 7 hingga 15 cm dari objek daun atau bunga mangrove.
5. Alat rekam citra foto mangrove menggunakan kamera *smartphone*.
6. Sistem yang dikembangkan hanya berbasis aplikasi mobile pada platform android.
7. Aplikasi yang dikembangkan hanya menerima masukan berupa gambar.
8. Mangrove yang diambil hanya berdasarkan daun dan bunga.
9. Pengambilan gambar dilakukan dengan pengaturan kamera menggunakan mode Auto Fokus.

1.4 Tujuan Penelitian

Tujuan utama yang ingin dicapai dari penelitian ini adalah untuk menguji seberapa akurat model algoritma *Faster R-CNN* dalam mengidentifikasi jenis mangrove.

1.5 Manfaat Penelitian

Adapun manfaat yang dapat diperoleh dari penelitian ini, antara lain:

1. Bagi peneliti dibidang kelautan dan teknologi, hasil dari penelitian ini dapat berfungsi sebagai referensi penelitian di masa depan tentang penerapan algoritma *Faster Region Convolutional Neural Network* untuk identifikasi jenis mangrove.
2. Bagi pembaca seperti mahasiswa dibidang teknologi, hasil dari penelitian ini dapat memberikan pengetahuan tentang *Faster Region Convolutional Neural Network* dalam melakukan identifikasi jenis mangrove.
3. Bagi kelompok Sadar Wisata dan masyarakat pada umumnya, hasil dari penelitian ini akan memberikan efisiensi dalam pengenalan jenis mangrove yang ada serta mendukung upaya pelestarian dan konservasi mangrove.

1.6 Sistematika Penulisan

Penulisan merupakan tahapan krusial dalam penyusunan skripsi. Berikut ini disajikan rincian tahapan penulisan yang dilakukan secara sistematis:

BAB I PENDAHULUAN

Bab ini berisi pemaparan mengenai latar belakang penelitian yang dilakukan, perumusan masalah, batasan masalah, tujuan dan manfaat penelitian, serta sistematika penulisan.

BAB II KAJIAN LITERATUR

Bab ini menjelaskan terkait kajian literatur berupa penelitian terdahulu yang relevan dengan topik penelitian yang dilakukan dan landasan teori sebagai dasar penelitian secara teoritis.

BAB III METODOLOGI PENELITIAN

Bab ini membahas tentang perancangan penelitian yang dilakukan secara seksama, mulai dari sub waktu penelitian, jenis penelitian,

instrumen penelitian, prosedur penelitian, studi pustaka, pengumpulan data, serta analisis dan perancangan.

BAB IV HASIL DAN PEMBAHASAN

Bab ini berisi pembahasan mengenai penelitian yang dilakukan, meliputi lingkungan uji coba yang digunakan di dalam penelitian, penjelasan rinci terkait proses yang terjadi secara bertahap hingga hasil yang diperoleh setelah penelitian dilaksanakan.

BAB V PENUTUP

Bab ini berisi kesimpulan dan saran yang diperoleh dari penelitian yang telah dilakukan.

DAFTAR PUSTAKA

Bab ini memuat daftar referensi yang digunakan sebagai acuan dalam proses penelitian.

BAB II

KAJIAN LITERATUR

2.1 Tinjauan Pustaka

Para penelitian di berbagai belahan dunia telah melakukan penelitian menggunakan metode *Faster Region Convolutional Neural Network* (*Faster R-CNN*) untuk mendeteksi objek diberbagai topik pembahasan. Berikut adalah beberapa penelitian yang telah dilakukan sebelumnya menggunakan metode *Faster R-CNN* dan yang berhubungan dengan identifikasi jenis mangrove.

Penelitian yang dilakukan oleh (Charli et al., 2020) tentang Implementasi Metode *Faster Region Convolutional Neural Network* untuk Pengenalan Jenis Burung Lovebird. Penelitian ini bertujuan untuk mengenali jenis burung serta mengidentifikasi motif atau warna aslinya. Hasil penelitian ini menunjukkan bahwa metode *Faster R-CNN* mampu mengenali jenis lovebird dengan tingkat akurasi sebesar 96% dan nilai *loss* sebesar 0,2%.

Penelitian yang dilakukan oleh (Pratama et al., 2024) tentang *Convolutional Neural Network* dan *Faster Region Convolutional Neural Network* Untuk Klasifikasi Kualitas Biji Kopi Arabika. Penelitian ini bertujuan untuk menganalisis kualitas biji kopi dalam proses grading yang sebelumnya dilakukan secara manual, yang memerlukan waktu yang lama dan biaya yang cukup besar. Hasil dari penelitian ini menunjukkan metode CNN-VGG16 mencapai akurasi sebesar 86% dan *Faster R-CNN* mencapai akurasi sebesar 93%.

Penelitian yang dilakukan oleh (Pujiono et al., 2024) tentang Application of *Faster R-CNN Deep Learning Method* for Rice Plant Disease Detection. Penelitian ini bertujuan untuk menerapkan metode *Faster R-CNN* dalam mendeteksi penyakit pada tanaman padi guna meningkatkan produksi pertanian serta mengurangi potensi kerugian hasil panen. Hasil penelitian ini menunjukkan bahwa model yang dikembang dapat mencapai akurasi sebesar 88%, dengan nilai *recall* dan *precision* masing masing sebesar 100% serta nilai *f1-score* sebesar 93%.

Penelitian yang dilakukan oleh (Romadhon & Setiyono, 2024) tentang Monitoring Pemakaian Masker Berbasis Video Menggunakan Metode *Faster R-CNN*. Penelitian ini bertujuan untuk mengklasifikasi dan mendeteksi jenis pemakaian masker. Hasil penelitian ini menunjukkan model mencapai rata-rata nilai *precision* sebesar 98,21%, *recall* sebesar 97% dan akurasi sebesar 95,36%

Penelitian yang dilakukan oleh (Rahim & Mineno, 2020) tentang Tomato flower detection and counting in greenhouses using *Faster Region-based Convolutional Neural Network*. Penelitian ini bertujuan untuk mendeteksi dan menghitung jumlah bunga tomat didalam rumah kaca guna mengoptimalkan produksi buah tomat. Hasil penelitian menunjukkan bahwa model yang diusulkan mampu melakukan identifikasi dengan tingkat *precision* sebesar 96,02% dan *recall* sebesar 93,09%.

Penelitian yang dilakukan oleh (Angel et al., 2024) tentang *Faster Region Convolutional Neural Network Based Facial Emotion Recognition*. Penelitian ini bertujuan untuk mengembangkan sistem *Facial Emotion Recognition* (FER) yang dirancang untuk mengenali emosi wajah. Hasil penelitian ini menunjukkan bahwa model mencapai akurasi sebesar 98,4% dengan nilai *precision* sebesar 97,2% dan *recall* sebesar 96,31%.

Penelitian yang dilakukan oleh (Ibitoye, 2024) tentang Fake Currency using Modified *Faster Region based Convolutional Neural Network*. Penelitian ini bertujuan untuk mendeteksi keberadaan mata uang palsu yang dapat berdampak negatif terhadap perekonomian suatu negara serta menurunkan nilai mata uang asli. Hasil penelitian menunjukkan bahwa metode ini dapat mengidentifikasi dengan akurasi sebesar 96%. Selain itu evaluasi lanjut menunjukkan bahwa model mencapai *Average Precision* (AP) dan akurasi sebesar 97% setelah 15 epoch.

Penelitian yang dilakukan oleh (Abas, 2022) tentang Diagnosing the Leukemia using *Faster Region based Convolutional Neural Network*. Penelitian ini bertujuan untuk mengdiagnosis penyakit leukemia yang memiliki tantangan dalam mengidentifikasi akibat bentuk sel darah putih (*White Blood Cells / WBC*) yang tidak beraturan serta inti sel yang terpelintir. Hasil dari penelitian ini dilakukan

pelatihan selama 50 *epoch* dengan ukuran *batch size* minimal 8 dan *learning rate* sebesar 0,01. Dapat mencapai akurasi *Average Precision (AP)* sebesar 97%.

Penelitian yang dilakukan oleh (Ji et al., 2021) tentang Bucket Teeth Detection Based on *Faster Region Convolutional Neural Network*. Penelitian ini bertujuan untuk mendeteksi kerusakan pada gigi *bucket* ekskavator yang dapat menganggu proses penggalian di area pertambangan, sehingga berpotensi menurunkan produktivitas kerja. Hasil penelitian menunjukkan bahwa model VGG-16 mencapai nilai *Average Precision (AP)* sebesar 0,9085 nilai *recall* sebesar 0,9962, *precision* sebesar 0,9124 dengan waktu komputasi 0,071 detik.

Penelitian yang dilakukan oleh (Asnur et al., 2023) tentang Identification of mangrove tree species using deep learning method. Penelitian ini bertujuan untuk mengetahui jenis mangrove dengan 3 jenis mangrove yang ditemukan yaitu *Avicenia marina*, *Avicenia officinalis*, *Rizophora apiculata*, *Sonneratia caseolaris*. Hasil penelitian ini menunjukkan akurasi *training* mencapai 97,50% sedangkan untuk *testing* akurasinya mencapai 81,25%.

Penelitian yang dilakukan oleh (Yixuan et al., 2023) tentang Aeroengine Blade Surface Defect Detection System Based On Improve *Faster R-CNN*. Penelitian ini bertujuan untuk mengatasi kesulitan pendekripsi bilah otomatis dan cacat yang tidak kontinu pada gambar. Hasil dari penelitian ini dengan menggunakan model *Faster R-CNN* mendapatkan *Average Precision (AP)* perkelas untuk *scratch* sebesar 62.9, AP untuk *bruise* sebesar 68.0, AP untuk *pockmark* sebesar 56.5 dan untuk mAP global sebesar 62.5.

2.2 Landasan Teori

2.2.1 Mangrove

Mangrove merupakan ekosistem utama dalam kehidupan diwilayah pesisir yang memiliki peran dalam menjaga keseimbangan siklus biologi lingkungan. Selain itu, mangrove adalah kelompok tumbuhan yang terdiri dari spesies tumbuhan yang memiliki hubungan taksonomi dengan famili yang tidak berkerabat tetapi memiliki adaptasi morfologi dan fisiologis terdapat habitat yang dipengaruhi oleh pasang surut (Edo et al., 2021).

Hutan mangrove di Indonesia memiliki keanekaragam jenis, tercatat sebanyak 202 jenis yang terdiri dari 89 jenis pohon, 5 jenis palem, 19 jenis liana, 44 jenis herba tanah, 44 jenis epifit dan 1 jenis paku. Hutan mangrove tumbuh pada tanah lumpur di daerah pantai dan muara sungai yang dipengaruhi pasang surut air laut oleh karena itu terdapat jenis-jenis pohon seperti *Avicennia*, *Sonneratia*, *Rhizophora*, *Bruguiera*, *Ceriops*, *Lumnitzera*, *Excoecaria*, *Xylocarpus*, *Aegiceras*, *Scyphiphora* dan *Nypa* (Rignolda, 2018).

Manfaat mangrove terdiri dari segi fisik yang berfungsi untuk mencegah abrasi, mengendalikan laju masuk air laut serta melindungi dari gelombang, angin kencang, bahaya tsunami dan menjaga stabilan pantai dari erosi. Segi biologi untuk sebagai tempat bertelur dan tempat berkembangbiak habitat alami dari berbagai jenis biota laut. Secara segi ekonomi dapat menjadi berbagai jenis bahan baku seperti sumber makanan, pewarna, bahan kosmetik, arang, kayu dan pakan ternak (Maryam et al., 2024).

2.2.2 Macam-macam Mangrove di Pulau Bintan

Penelitian yang dilakukan oleh (Apdillah et al., 2023) terdapat jenis mangrove yang telah teridentifikasi sebanyak 11 jenis mangrove dikawasan Sungai Pengudang, Pulau Bintan yaitu *Rhizophora mucronata*, *Rhizophora apiculata*, *Bruguiera gymnorhiza*, *Xylocarpus granatum*, *Ceriops tagal*, *Avicennia alba*, *Scyphiphora hydrophyllacea*, *Sonneatia alba*, *Sonneratia marina*, *Nypa fruticans*, *Pandanus tectorius*.

Selanjutnya penelitian yang dilakukan oleh (Darmayanti & Anggraini, 2024) telah menemukan jenis mangrove sebanyak 5 jenis diwilayah Pesisir Kawal, Pulau Bintan yaitu *Rhizophora apiculata*, *Rhizophora mucronata*, *Xylocarpus granatum*, *Lumnitzera Littorea*, *Hibiscus Tiliaceus* dan penelitian yang dilakukan oleh (Immanuel & Nasution, 2020) dikawasan hutan mangrove Dompak Kota Tanjungpinang, Pulau Bintan telah menemukan jenis mangrove sebanyak 10 jenis mangrove yaitu *Avicennia Lanata*, *Bruguiera gymnorhiza*, *Bruguiera cylindrica*, *Hibiscus Tiliaceus*, *Nypa fruticans*, *Rhizophora apiculata*, *Rhizophora stylosa*, *Sonneratia Alba*, *Scyphiphora hydrophyllacea* dan *Xylocarpus granatum*.

Penelitian ini jenis mangrove yang ingin diteliti sebanyak 9 jenis mangrove yang banyak ditemui di kawasan Pulau Bintan yaitu *Avicennia Lanata*, *Bruguiera cylindrica*, *Bruguiera gymnorhiza*, *Rhizophora apiculata*, *Scyphiphora hydrophyllacea*, *Lumnitzera littorea*, *Sonneratia Alba*, *Xylocarpus granatum* dan *Rhizophora mucronata*.

Jenis mangrove yang dipakai oleh peneliti ini didukung oleh teori dari buku yang dibuat oleh (Rignolda, 2018) dan beberapa jurnal dari penelitian sebelumnya yang dijelaskan oleh peneliti (Pototan et al., 2021; Soeprobawati et al., 2022; Liubana et al., 2022; Maryam et al., 2024) untuk penentuan genus, spesies serta karakteristik setiap jenis mangrove, termasuk bentuk daun, bunga dan warnanya, akan merujuk pada buku dan jurnal yang telah disebutkan sebagai referensi peneliti. Berikut lebih lengkap mengenai 9 jenis mangrove yang diambil pada tabel 2.1 dibawah ini :

Tabel 2. 1 Jenis Mangrove Yang Diambil

Gambar	Taksonomi	Keterangan
	<p>Kingdom: <i>Plantae</i> Divisi: <i>Magnoliophyta</i> Kelas: <i>Magnoliopsida</i> Ordo: <i>Lamiales</i> Famili: <i>Acanthaceae</i> Genus: <i>Avicennia</i> Spesies: <i>Avicennia Lanata</i></p>	<p>Daun : bagian bawah daun putih kekuningan dan ada rambut halus. Bentuk daunnya elips serta ujungnya membundar dan agak meruncing.</p> <p>Bunga: bergombolan muncul di ujung tandan, berwarna kuning pucat agak jingga tua</p>
	<p>Kingdom: <i>Plantae</i> Divisi: <i>Magnoliophyta</i> Kelas: <i>Magnoliopsida</i> Ordo: <i>Myrales</i> Famili: <i>Rhizophoraceae</i> Genus: <i>Bruguiera</i> Spesies: <i>Bruguiera gymnorhiza</i></p>	<p>Daun: Daun berkulit, berwarna hijau pada lapisan atas dan hijau kekuningan pada bagian bawahnya dengan bercak-bercak.</p> <p>Bentuknya elips sampai elips-lanset serta ujungnya meruncing.</p> <p>Bunga: berwarna merah dengan ukuran yang kecil berbentuk seperti tabung.</p>

Gambar	Taksonomi	Keterangan
 	<p>Kingdom: <i>Plantae</i> Divisi: <i>Magnoliophyta</i> Kelas: <i>Magnoliopsida</i> Ordo: <i>Myrales</i> Famili: <i>Rhizophoraceae</i> Genus: <i>Bruguiera</i> Spesies: <i>Bruguiera cylindrica</i></p>	<p>Daun : Permukaan hijau cerah. Bentuknya elips serta ujungnya agak meruncing.</p> <p>Bunga: berwarna kuningan kehijauan, serta berbentuk tabung dengan kelopak menyatu.</p>
 	<p>Kingdom: <i>Plantae</i> Divisi: <i>Magnoliophyta</i> Kelas: <i>Magnoliopsida</i> Ordo: <i>Myrales</i> Famili: <i>Combretaceae</i> Genus: <i>Lumnitzera</i> Spesies: <i>Lumnitzera littorea</i></p>	<p>Daun : daunya berbentuk elips atau membuat dengan ujung lebih lebar dari pangkal, berwarna hijau cerah serta ukuran daun yang kecil.</p> <p>Bunga: bunga berwarna merah terang, terdapat benang sari berwarna kuning di ujung bunganya.</p>

Gambar	Taksonomi	Keterangan
 	<p>Kingdom: <i>Plantae</i> Divisi: <i>Magnoliophyta</i> Kelas: <i>Magnoliopsida</i> Ordo: <i>Myrales</i> Famili: <i>Rhizophoraceae</i> Genus: <i>Rhizophora</i> Spesies: <i>Rhizophora apiculata</i></p>	<p>Daun: Daun berkulit dengan warna hijau tua dengan hijau muda dibagian tengah. Berbentuk elips menyemping serta ujungnya meruncing.</p> <p>Bunga: berwarna kekuningan serta berkelompok dua-dua.</p>
 	<p>Kingdom: <i>Plantae</i> Divisi: <i>Tracheophyta</i> Kelas: <i>Magnoliopsida</i> Ordo: <i>Malpighiales</i> Famili: <i>Rhizophoraceae</i> Genus: <i>Rhizophora</i> Spesies: <i>Rhizophora mucronata</i></p>	<p>Daun: daunnya berkulit, daunnya berwarna hijau dengan bentuk elips melebar hingga bulat memanjang serta ujungnya meruncing.</p> <p>Bunga: bunga berbentuk Bintang kecil, berwarna kuning kehijauan atau krem pucat.</p>

Gambar	Taksonomi	Keterangan
 	<p>Kingdom: <i>Plantae</i> Divisi: <i>Magnoliophyta</i> Kelas: <i>Magnoliopsida</i> Ordo: <i>Rubiales</i> Famili: <i>Rubiaceae</i> Genus: <i>Scyphipora</i> Spesies: <i>Scyphipora hydrophyllacea</i></p>	<p>Daun: daunya berbentuk lonjong hingga elips dengan ujungnya membulat, warna daunya mengkilap.</p> <p>Bunga: bunganya berwarna putih atau krem, berbentuk kecil seperti bintang.</p>
 	<p>Kingdom: <i>Plantae</i> Divisi: <i>Magnoliophyta</i> Kelas: <i>Magnoliopsida</i> Ordo: <i>Myrales</i> Famili: <i>Sonneratiaceae</i> Genus: <i>Sonneratia</i> Spesies: <i>Sonneratia Alba</i></p>	<p>Daun: daunya berkulit, berbentuk seperti telur terbalik, serta ujungnya membundar.</p> <p>Bunga: bunganya berwarna merah serta memiliki benang sari yang keluar berwarna putih agak kekuningan.</p>

Gambar	Taksonomi	Keterangan
 	Kingdom: <i>Plantae</i> Divisi: <i>Magnoliophyta</i> Kelas: <i>Magnoliopsida</i> Ordo: <i>Sapindales</i> Famili: <i>Meliaceae</i> Genus: <i>Xylocarpus</i> Spesies: <i>Xylocarpus granatum</i>	Daun: daunnya agak tebal, susunan daun berpasangan. Bentuknya elips seperti bulat terus terbalik, ujungnya membundar Bunga : bunganya berwarna krem atau kuning kecoklatan. Bentuknya kecil .

2.2.3 Deep Learning


Deep learning terinspirasi dari cara kerja otak manusia dan memungkinkan komputer untuk belajar secara langsung dari data seperti gambar, suara atau jenis data lainnya, melalui jaringan saraf tiruan yang kompleks. *Deep learning* merupakan cabang dari kecerdasan buatan yang telah membawa revolusi dalam pengenalan citra digital. Dengan struktur jaringan saraf tiruan yang mendalam, teknologi ini memungkinkan komputer untuk menganalisis lingkungan secara lebih intuitif, mengenali objek visual serta mendeteksi berbagai benda di sekitarnya, serupa dengan cara manusia dalam memahami dunia (Rizki et al., 2023).

Salah satu keunggulan utama *deep learning* adalah kemampuannya dalam mencapai tingkat akurasi yang tinggi. Salah satu contoh penerapan *deep learning* dalam pengenalan citra adalah *Convolutional Neural Network* (CNN), yang

merupakan pengembangan lebih lanjut dari *Multi-Layer Perceptron* (MLP) (Zhou et al., 2020).

2.2.4 Convolutional Neural Network (CNN)

Convolutional Neural Network (CNN) adalah salah satu algoritma *deep learning* yang dikembangkan dari *Multi-Layer Preceptron* (MLP) untuk menangani data berdimensi tinggi seperti gambar dan video. *Convolutional Neural Network* (CNN) digunakan untuk memecahkan masalah komputer seperti mobil tanpa pengemudi, robotika, drone, keamanan dan diagnosis medis yang menggunakan gambar sebagai inputan (López et al., 2022). Arsitektur CNN terdiri dari beberapa lapisan tersembunyi (*hidden Layers*) dan terbagi menjadi dua tahap utama yaitu *feature learning* dan *classification*. Tahapan *feature learning* mencakup *input layer*, *convolutional layer*, ReLU(fungsi aktivasi) dan *pooling layer*, sementara tahap *classification* terdiri dari *flatten layer*, *fully-connected layer* dan tahap prediksi atau *output layer* (Sutama et al., 2020).



Gambar 2. 1 Arsitektur *Convolutional Neural Network*

(Sumber: López et al., 2022)


Berikut merupakan penjelasan terkait urutan penggunaan algoritma *Convolutional Neural Network* oleh (Azmi et al., 2023).

a. *Input Layer*

Lapisan ini berfungsi sebagai tempat penerimaan nilai piksel dari citra yang diinputkan kedalam sistem. Citra yang digunakan sebagai masukan terdiri dari tiga saluran warna utama yaitu *Red*, *Green* dan *Blue* (RGB).

b. *Convolutional Layer*

Lapisan konvolusi (*convolutional Layer*) terdiri dari neuron yang tersusun dalam suatu pola tertentu sehingga membentuk filter dengan panjang dan tinggi tertentu. Proses konvolusi dilakukan menggunakan *kernel* dan *stride*, dimana konvolusi merupakan kombinasi antara dua matriks berbeda untuk menghasilkan matriks baru. *Stride* adalah jarak pengeseran *kernel* pada setiap operasi konvolusi, yang memungkinkan pengaturan model secara lebih spesifik, selain itu *kernel* merupakan matriks kecil yang berguna untuk mengekstraksi fitur penting seperti tepi, sudut atau pola tertentu dan *padding* digunakan karena keterbatasan dari proses konvolusi yang dapat menghilangkan informasi pada bagian tepi citra, sehingga dapat diatasi dengan menggunakan metode *zero padding* (Taye, 2023). Operasi ini menerapkan fungsi keluaran sebagai *feature map* dari citra masukan (Azmi et al., 2023). Tujuan utama dari proses konvolusi pada data gambar adalah untuk mengekstraksi fitur yang terdapat dalam citra guna digunakan pada tahap pemrosesan berikutnya (Nugroho et al., 2023).



Gambar 2. 2 *Convolutional Layer*

(Sumber: Zhao et al., 2024)

Contoh gambar 2.2 diatas, digunakan citra masukan berukuran 5×5 dengan *kernel* berukuran 3×3 , yang diterapkan mulai dari sisi kiri. Prosedur ini dikenal sebagai *sliding windows*. Persamaan berikut digunakan untuk menghitung proses konvolusi :

$$\alpha \cdot b = \sum_{i=1}^n \alpha_i b_i = \alpha_1 b_1 + \alpha_2 b_2 + \dots + \alpha_n b_n \quad (2.1)$$

Memahami lebih lanjut cara kerja operasi konvolusi dalam ekstraksi fitur, persamaan berikut digunakan menentukan *feature map*. *Feature map* merupakan hasil dari proses konvolusi antara citra masukan dan *kernel*, yang bertujuan untuk menangkap pola penting dari citra dengan mempertimbangkan nilai piksel di sekitarnya. Operasi ini dilakukan dengan menggeser (*sliding*) *kernel* pada seluruh area citra dan melakukan perkalian elemen-elemen yang sesuai, kemudian menjumlahkan hasilnya. Nilai akhir dari proses ini membentuk *feature map*, yang akan digunakan dalam tahap pemrosesan berikutnya untuk mengidentifikasi fitur yang lebih kompleks (Nugroho et al., 2023). Persamaan berikut merepresentasikan perhitungan *feature map* :

$$n_{out} = \left\lceil \frac{n_{in} + 2p - k}{s} \right\rceil + 1 \quad (2.2)$$

Dimana :

- n_{out} : number of input features
- n_{in} : number of output features
- k : convolution kernel size
- p : convolution padding size
- s : convolution stride size

c. Rectified Linier Unit (ReLU)

Rectified Linear Unit (ReLU) merupakan salah satu fungsi aktivasi yang digunakan dalam jaringan saraf tiruan (*neural network*). Fungsi aktivasi ini bersifat non-linear dan berperan dalam menentukan nilai keluaran berdasarkan nilai masukan yang diberikan. ReLU menghasilkan keluaran bernilai nol ketika menerima masukan negatif, sedangkan untuk masukan positif, nilai keluarannya akan sama dengan nilai masukannya (Sutama et al., 2020). Secara matematis, fungsi ini dapat dinyatakan sebagai berikut:

$$ReLU(x) = \begin{cases} 0, & x < 0, \\ x, & x \geq 0, \end{cases} \quad (2.3)$$

Dimana variable x adalah hasil keluaran dari fungsi aktivasi ReLU. Contoh perhitungan pada ReLU dapat di lihat pada dibawah ini.

17	-3	10	7
-3	-6	9	-10
-9	2	-9	-14
0	-6	-7	-2

→

17	0	10	7
0	0	9	0
0	2	0	0
0	0	0	0

Gambar 2. 3 Proses Perhitungan ReLU

(Sumber: Sutama et al., 2020)


d. *Pooling Layer*

Pooling Layer berfungsi untuk menyederhanakan *feature map* melalui proses *downsampling* dengan tujuan mengurangi dimensi spasial dari representasi fitur pada lapisan *konvolusional*. Proses ini secara langsung mengurangi jumlah parameter yang diperlukan, sehingga dapat menekan kebutuhan sumber daya komputasi serta mempercepat proses komputasi. Selain itu, *pooling layer* juga berperan dalam mengekstraksi fitur utama guna meningkatkan efisiensi dalam proses pelatihan model (Permana et al., 2024).

Terdapat dua jenis *pooling layer* yang umum digunakan yaitu *Max Pooling* dan *Average Pooling*. *Max Pooling* mengambil nilai maksimum dari dalam citra yang tercakup oleh *kernel*. *Average Pooling* menghitung nilai rata-rata dari area tersebut. Adapun persamaan dari *max pooling* sebagai berikut ini (Nugroho et al., 2023):

$$\begin{aligned} & \text{Pool}_{x,y} \\ &= \text{Max}(\text{Conv}_{x,y}, \text{Conv}_{x+1,y}, \text{Conv}_{x,y+1}, \text{Conv}_{x+1,y+1}) \end{aligned} \quad (2.4)$$

Berikut adalah contoh gambar *pooling layer* pada operasi *max pooling* dan *average pooling*.




Gambar 2. 4 Pooling Layer

(Sumber: Zhao et al., 2024)

e. *Flatten*


Penelitian yang dilakukan oleh (Nugroho et al., 2023) mengatakan lapisan *Flatten* berfungsi untuk mengubah *feature map* yang berbentuk *multidimensional array* menjadi vektor satu dimensi. Proses ini diperlukan agar lapisan *Fully Connected* dapat menerima dan memproses data secara optimal sebagai masukan dalam tahap klasifikasi. Berikut contoh gambar dari proses *Flatten*.



Gambar 2. 5 Flatten

f. *Fully Connected*

Full connected layer merupakan lapisan dalam jaringan saraf tiruan yang berfungsi sebagai *feed-forward layer* untuk mengolah fitur yang telah diekstraksi oleh lapisan konvolusi dan *pooling*. Lapisan ini terdiri dari *hidden layer*, fungsi aktivasi (*activation function*), lapisan keluaran (*output layer*) dan fungsi kerugian (*loss function*). Setiap neuron dalam *Fully Connected layer* terhubung dengan seluruh neuron di lapisan berikutnya, memungkinkan jaringan menangkap hubungan kompleks antara fitur yang telah diproses sebelumnya. Selain itu, lapisan ini berperan dalam mengoptimalkan bobot parameter guna memastikan bahwa fitur yang telah dipelajari dapat dikategorikan dengan benar serta meningkatkan akurasi model dalam tugas klasifikasi dan deteksi objek (Nugroho et al., 2023).


Gambar 2. 6 *Fully Connected*

(Sumber: Azmi et al., 2023)

2.2.5 Arsitektur ResNet-50

ResNet-50 merupakan salah satu arsitektur dalam *Convolutional Neural Network* (CNN) yang di perkenalkan untuk mengatasi masalah *vanishing gradient* yang sering terjadi pada jaringan yang semakin dalam. Arsitektur ini memperkenalkan konsep *shortcut connections* atau *skip connections*, yang memungkinkan fitur dari lapisan sebelumnya digunakan kembali sebagai masukan pada lapisan berikutnya (Nashrullah et al., 2020).

ResNet-50 terdiri dari 50 lapisan yang meliputi 48 lapisan konvolusi, satu *max pooling* dan satu lapisan *average pooling*. Arsitektur ini menggunakan *residual blocks* yang terdiri dari dua atau tiga lapisan konvolusi dengan ukuran 1×1 , 3×3 , dan 1×1 serta lapisan normalisasi (*batch normalization*) dan fungsi aktivasi ReLU (*Rectified Linear Unit*). *Residual block* memungkinkan jaringan untuk belajar representasi fitur yang lebih baik dengan mengurangi kehilangan informasi selama proses konvolusi. Secara keseluruhan, ResNet-50 memiliki lima tahap proses konvolusi yang di akhiri dengan *average pooling*, sebelum akhirnya masuk kedalam *Fully Connected layer* untuk proses klasifikasi (Salim et al., 2023).



Gambar 2. 7 Arsitektur ResNet-50

(Sumber: Ifayatin et al., 2024)

2.2.6 Feature Pyramid Network (FPN)

Feature Pyramid Network (FPN) merupakan jaringan dari serangkaian fitur yang dirancang untuk dapat menghasilkan informasi semantik yang kuat di berbagai skala yang beragam sehingga mendapatkan hasil yang lebih detail yang berguna untuk objek yang kecil sehingga kesalahan dalam mendeteksi objek kecil dapat meminimalisirkan, kemudian dikirim ke jaringan selanjutnya untuk melakukan tugas prediksi (Hu & Wang, 2020).

Feature Pyramid Network (FPN) terdiri dari jalur *Bottom-Up*, jalur *Top-Down* dan koneksi lateral. Gambar dimulai akan dikirim ke jaringan fitur yang telah dilatih sebelumnya seperti ResNet dan lain-lainnya (Chen et al., 2023). jalur *Bottom-Up* meliputi proses ekstraksi fitur ke depan dalam jaringan konvolusional lebih dalam atau detail, sedangkan jalur *Top-Down* melibatkan *upsampling* peta fitur dari lapisan konvolusional terakhir. Kemudian koneksi lateral yang memainkan peran penting dalam mengabungkan fitur lapisan konvolusional dalam dengan informasi semantik yang kaya dan dangkal dengan resolusi tinggi (Pan et al., 2024). Proses ini akan menghasilkan matriks fitur yang berisi informasi tentang objek besar dan kecil dalam gambar. Matriks fitur gabungan ini kemudian dimasukkan kedalam RPN untuk penentuan kotak jangkar untuk langkah selanjutnya (Hou et al., 2024).

2.2.7 Region Proposal Network (RPN)

Region Proposal Network (RPN) berfungsi untuk menghasilkan proposal wilayah berdasarkan fitur yang diekstraksi dari citra masukan. Pada tahap ini, diperkenalkan konsep anchor yaitu mekanisme untuk menentukan wilayah objek yang potensial dalam gambar. Setiap *anchor* dipusatkan pada *sliding windows* berukuran 3 x 3 dan memiliki sembilan kombinasi yang terdiri dari tiga skala berbeda (128 2, 256 2, 512 2) serta tiga rasio aspek (1:1, 1:2, 2:1). Lapisan klasifikasi kotak (*box-classification layer*) bertugas menentukan apakah suatu *anchor* merupakan kandidat positif atau bukan, sedangkan lapisan regresi kotak (*box-regression layer*) digunakan untuk menghasilkan koordinat *bounding box* yang lebih akurat dalam mendeteksi objek (Pardede & Hardiansah, 2022). Untuk melatih RPN, loss function didefinisikan sebagai berikut :

$$L = \frac{1}{N_{cls}} \sum L_{cls} (p, p^*) + \lambda \frac{1}{N_{reg}} \sum p * L_{reg} (t, t^*) \quad (2.5)$$

Keterangan :

p adalah kemungkinan proposal menjadi objek

p* adalah label sebenarnya dari proposal (ketika proposal adalah objek,

p * = 1, jika tidak p * = 0)

t dan t * adalah koordinat dari *bounding box regression* dan *ground-truth* masing-masing, N_{cls} dan N_{reg} adalah dua parameter normalisasi

L_{cls} adalah kerugian klasifikasi, itu adalah kerugian log selama dua kelas (objek dan bukan keberatan).

L_{reg} adalah kerugian regresi istilah p * L_{reg} berarti kerugian regresi diaktifkan hanya untuk *anchor* positif.

$$t_x = \frac{(x - x_a)}{w_a} \quad t_y = \frac{(y - y_a)}{h_a} \quad (2.6)$$

$$t_w = \log\left(\frac{w}{w_a}\right) \quad t_h = \log\left(\frac{h}{h_a}\right) \quad (2.7)$$

$$t *_{x^*} = \frac{(x^* - x_a)}{w_a} \quad t *_{y^*} = \frac{(y^* - y_a)}{h_a} \quad (2.8)$$

$$t *_{w^*} = \log\left(\frac{w^*}{w_a}\right) \quad t *_{h^*} = \log\left(\frac{h^*}{h_a}\right) \quad (2.9)$$


Untuk regresi kotak pembatas, parameter dari empat koordinat ditujukan pada persamaan (6). Dimana x dan y mewakili koordinat dari pusat kotak, w dan mewakili berat dan tinggi dari kota pembatas masing masing, c, xa, dan x* untuk kotak yang diprioritaskan, kotak jangkar, dan *ground-truth box* masing-masing (demikian juga untuk y, w, h). Ini bisa berupa pemikiran *bounding box regression* dari kotak *anchor* ke kotak kebenaran dasar terdekat (Pardede & Hardiansah, 2022).

2.2.8 Region of Interest Pooling Layer (ROI Pooling)

Region of Interest (ROI) Pooling berfungsi untuk menyesuaikan ukuran fitur dari suatu wilayah tertentu (ROI) agar memiliki dimensi tetap sebelum diproses oleh lapisan *Fully Connected*. Proses ROI Pooling adalah memetakan ROI dari gambar asli kedalam *feature map* hasil konvolusi. ROI merupakan wilayah dalam gambar yang mengandung objek yang ingin dianalisis, umumnya didefinisikan dalam bentuk empat nilai *tuple* (r, c, h, w). Untuk (r,c) menunjukkan koordinat sudut kiri atas dari ROI, sedangkan (h,w) merepresentasikan tinggi dan lebar wilayah tersebut (Pardede & Hardiansah, 2022).

Wilayah ini kemudian dibagi menjadi beberapa bagian kecil dalam bentuk grid dengan ukuran tetap. Seperti yang ditunjukkan pada gambar 9, kotak biru menandai ROI, sementara garis merah menunjukkan bagaimana wilayah tersebut dibagi kedalam grid yang lebih kecil (Ji et al., 2021). Ukuran grid ini tidak selalu

tetap, melainkan ditentukan berdasarkan hiperparameter $H \times W$, H dimana jumlah pembagian vertikal dan W mewakili pembagian horizontal. Dalam berbagai implementasi $H \times W$ dapat berbeda, ukuran grid yang umum digunakan adalah 7×7 , 14×14 atau 2×2 . Setiap bagian dalam grid kemudian menjalani proses *max pooling*, dimana nilai maksimum dipilih sebagai representasi fitur (Pardede & Hardiansah, 2022). Hasil akhirnya berupa dimensi tetap sebesar $H \times W$ yang telah ditetapkan.




2.2.9 Intersection over Union (IoU)

Intersection over Union atau IoU adalah suatu metode untuk evaluasi yang digunakan untuk mengukur akurasi deteksi objek terhadap suatu citra yang tumpang tindih antara 2 batas. IoU mempunyai 2 area yaitu *intersection* dan *union*. *Intersection* mengacu pada area perpotongan antara *ground-truth box* yang merupakan *bounding box* sebenarnya dan area yang terdeteksi dari model yang dibangun (Pardede & Hardiansah, 2022). Secara umum, nilai ambang batas (*threshold*) untuk *Intersection over Union* (IoU) berkisaran antara 0,5 hingga 0,8 dalam mengklasifikasi apakah prediksi tersebut benar atau salah (Ahmed et al., 2023) . Berikut persamaan dari IoU :

$$IoU = \frac{|A \cap B|}{|A \cup B|} \quad (2.10)$$

$|A \cap B|$ berarti area tumpang tindih dan $|A \cup B|$ adalah area gabungan dari area *bounding box* yang diprediksi dari area *ground truth*. Berikut adalah gambar dari *Intersection over Union* :




Gambar 2. 9 *Intersection over Union*

(Sumber: Pardede & Hardiansah, 2022)

2.2.10 Faster Region Convolutional Neural Network

Faster Region Convolutional Neural Network (*Faster-RCNN*) merupakan salah satu metode deteksi objek berbasis *Convolutional Neural Network* (CNN) yang terdiri dari dua modul utama yaitu *Region Proposal Network* (RPN) dan *Fast Region-based Convolutional Neural Network* (*Fast R-CNN*) (Ahmed et al., 2023). *Region Proposal Network* (RPN) berfungsi untuk menghasilkan wilayah kandidat yang berpotensi mengandung objek dan yang paling penting dari arsitektur *Faster R-CNN*. Setelah wilayah kandidat diperoleh dari RPN, proposal tersebut diteruskan ke modul kedua yaitu *Fast R-CNN*. Modul ini menggunakan fitur yang dihasilkan oleh lapisan konvolusi CNN untuk melakukan klasifikasi objek dan penyempurnaan prediksi *bounding box*, proses ini dimulai melalui pemetaan wilayah proposal kedalam dimensi yang lebih rendah melalui *ROI Pooling Layer* dengan dikuti dengan ekstraksi fitur menggunakan *Fully Connected Layer*. Kemudian dilakukan klasifikasi objek serta regresi posisi *bounding box* untuk meningkatkan presisi deteksi (Pardede & Hardiansah, 2022).



Gambar 2. 10 Arsitektur *Faster R-CNN*

(Sumber: Ahmed et al., 2023)

Tahap pelatihan, *Faster R-CNN* menggunakan empat langkah utama yaitu melatih *Region Proposal Network* (RPN), melatih jaringan *Fast R-CNN*

menggunakan *region proposal* yang dihasilkan dari RPN, memperbaharui RPN dengan berbagai bobot dengan *Fast R-CNN* dan melatih ulang *Fast R-CNN* menggunakan RPN yang telah di perbaharui. Struktur RPN terdiri dari dua jaringan utama. Jaringan pertama adalah CNN yang lima lapisan terakhirnya diganti dengan konvolusi 3x3, diikuti oleh lapisan ReLU, lapisan konvolusi 1x1 serta lapisan klasifikasi yang menggunakan fungsi *softmax*. Jaringan kedua terdiri dari dua lapisan utama yaitu lapisan konvolusi 1x1 untuk kotak regresi (RPN) dan lapisan keluaran regresi dengan fungsi *Smooth-L1 loss* (Pratama et al., 2024).

Langkah-langkah algoritma Faster R-CNN dijelaskan oleh (Yan et al., 2021) sebagai berikut ini :

a. Input Gambar

Tahap ini gambar akan masuk kedalam konvolusi untuk mendapatkan *feature maps*.

b. *Convolutional Layer*

Pada tahap ini *Convolutional Layer* menggunakan sebuah metode *Convolutional Neural Network* dengan arsitektur ResNet-50 sebagai *backbone* untuk mengekstrak fitur yang akan menghasilkan *feature maps*.

c. *Region Proposal Network (RPN)*

Selanjutnya setelah mendapatkan *feature maps*, kemudian masuk ketahap RPN, RPN akan menghasilkan sebuah *anchor* untuk menentukan suatu wilayah atau lokasi kemungkinan memiliki objek pada gambar. RPN terdiri dari dua lapisan yaitu *box-classification Layer* untuk menentukan suatu *anchor* itu objek atau bukan dan *box-regression Layer* untuk menghasilkan koordinat *bounding box* dalam mendeteksi objek. Untuk kedua lapisan tersebut dapat menggunakan persamaan (2.5).

d. *Non-Maximum Suppression* (NMS)

Pada tahap ini, setelah memperoleh *region proposal* dari RPN, untuk mengurangi jumlah proposal dan menghilangkan *bounding box* yang tumpang tindih dan memilih *bounding box* terbaik berdasarkan *confidence score* menggunakan *threshold Intersection over Union* (IoU) untuk itu dapat menggunakan persamaan (2.10).

e. *Region of Interest* (ROI Pooling)

Pada tahap ini, setelah menerima nilai dari setiap *region proposal* dari RPN, selanjutnya ROI berfungsi untuk menyesuaikan wilayah *region proposal* dengan ukuran yang tetap sebelum masuk ke dalam *Fully Connected*.

f. *Fully Connected*

Pada tahapan ini, terdapat 2 komponen utama yaitu *classification* dan *bounding box regression*. Fungsi loss seperti berikut ini (Ji et al., 2021):

1) *Classification loss* (softmax)

Classification (softmax) digunakan untuk menentukan jenis objek dalam *bounding box*, yang dimana p_u adalah output klasifikasi untuk kelas baru.

$$L_{cls}(p, u) = -\log p_u \quad (2.11)$$

2) *Bounding box regression*

Bounding box regression digunakan untuk menyesuaikan koordinat prediksi agar lebih dekat ke *ground truth* yang dimana t^* adalah *ground truth*.

$$L_{reg}(t, t^*) = \sum_{x,y,w,h} Smooth_{L1}(t_i - t_i^*) \quad (2.12)$$

2.2.11 Average Precision (AP)

Average Precision (AP) merupakan metrik evaluasi dasar yang dipergunakan untuk mengukur akurasi suatu objek untuk kelas tertentu yang menjadikan alat yang berharga untuk pembandingan kinerja. Terdapat varian dalam AP yaitu AP 50 dan AP75, varian ini berfokus pada rentang tertentu dalam ambang batas IoU (*Intersection over Union*). AP50 mempertimbangkan ambang batas 50% sedangkan AP 75 menggunakan ambang batas 75% (Tian et al., 2024). Secara umum, nilai yang paling digunakan adalah 50% dan 75% yang dilaporkan sebagai AP 50 dan AP75 (Padilla et al., 2020). Berikut adalah persamaan *Average Precision* (AP) yang menghitung rata-rata dari *precision* dan *recall* (Chen et al., 2023).

$$AP = \int_0^1 P(R)dR \quad (2.13)$$

2.2.12 Mean Average Precision (mAP)

Mean Average Precision (mAP) merupakan nilai rata-rata dari *Average Precision* (AP) dari semua kelas atau kategori dari keseluruhan model yang berfungsi sebagai salah satu metrik evaluasi utama yang digunakan dalam tugas mendeteksi objek multi kelas (Li, 2021). mAP memiliki beberapa varian yang berfokus pada ambang batas (IOU) seperti mAP 50 (0.5) dan mAP 50-95 (0.5-0.95) (Padilla et al., 2021).

Dataset MS COCO (Microsoft Common Objects in Context) yang merupakan kumpulan data COCO untuk deteksi objek yang besar dan kaya segmentasi dan data teks. Mencakup 91 jenis target, 328.00 gambar dan 2,5 juta label dengan kumpulan data segmentasi semantik paling besar. Memperkenalkan metode indeks lebih ketat untuk mengukur kinerja deteksi. Tidak seperti Dataset Pacal VOC dan ILSVCR, MS COCO menghitung rentang ambang batas IoU dari 0,5 sampai 0,95 (Zaidi et al., 2021). Berikut persamaan *Mean Average Precision* (mAP) (Hou et al., 2024).

$$mAP = \frac{1}{N} \sum_i^N AP_I \quad (2.14)$$

2.2.13 Python

Python merupakan salah satu bahasa pemrograman yang bisa banyak digunakan di berbagai bidang. Kode python sangat mudah di pahami bagi pemula maupun bagi yang sudah menguasai bahasa pemrograman lain. Komunitas serta perpustakaan yang dimiliki oleh python salah satu menjadi alasan python menjadi serba guna untuk segala jenis aplikasi dari pemograman statistik ataupun pembelajaran mesin (*machine learning*) dan pembelajaran mendalam (*deep learning*) dan banyak kegunaan di berbagai bidang. Python merupakan bahasa pemrograman yang dikembangkan di tahun 1991 oleh Guido van Rossum, bahasa ini mendukung struktur pemrograman Berorientasi Objek sehingga sangat multifungsi untuk di pelajari (Junaidi et al., 2023).

2.2.14 Transfer Learning

Transfer Learning adalah suatu cara yang menggunakan model *pre-trained* atau model yang sudah dilatih pada suatu dataset yang banyak untuk menyelesaikan permasalahan lain yang serupa dengan cara menggunakanya sebagai *starting point*, lalu memodifikasi dan memperbarui parameternya sehingga sesuai dengan dataset pada permasalahan yang baru. Contoh dari implementasi transfer learning yaitu menggunakan model *pre-trained* yang dilatih untuk mengenali mobil, kemudian model tersebut digunakan untuk mengenali truk (Wijaya et al., 2021).

Transfer Learning membuat proses pelatihan data menjadi lebih efisien dikarenakan model sudah memiliki pemahaman yang kuat dalam mengenali fitur dan pola dasar data yang dapat meningkatkan kinerja model, sehingga menghasilkan akurasi yang lebih baik. Proses transfer learning dimulai dari memuat data yang digunakan untuk melatih model dan biasanya diikuti dengan augmentasi data untuk mengurangi overfitting (Jiemesha & Wonohadidjojo, 2025).

2.2.15 Parameter yang digunakan

Secara umum, berbagai penelitian sebelumnya telah mengkaji penggunaan sejumlah parameter dalam proses pelatihan model pada algoritma *Faster R-CNN*. Parameter yang digunakan antara lain *Stochastic Gradient Descent* (SGD) sebagai *optimizer*, *learning rate*, *momentum*, *weight decay*, *epoch* dan *batch size*. Pemilihan parameter ini memiliki peran yang penting dalam proses pembelajaran model secara langsung mempengaruhi performa model yang dilatih.


Salah satu parameter penting dalam proses pelatihan adalah *batch size* yaitu jumlah sampel data yang diproses secara bersamaan dalam satu iterasi estimasi gradien. Ukuran *batch* yang kecil cenderung menghasilkan generalisasi model yang lebih baik dibandingkan *batch* berukuran besar, dengan kisaran optimal umumnya berada antara 2 hingga 32. Secara umum yang sering digunakan adalah ukuran *batch* sebesar 16, 32 dan 64 sering digunakan tergantung kombinasi dari *hiper paramater* lainnya. *Epochs* adalah jumlah iterasi dalam lintasan penuh untuk jaringan saraf selama pelatihan (Raiaan et al., 2024).

Learning rate adalah parameter yang mengontrol seberapa banyak bobot model diperbarui sebagai respons terhadap kesalahan yang diantisipasi dalam setiap iterasi. Nilai yang terlalu kecil dapat menyebabkan prosedur pelatihan yang panjang dengan kesalahan pelatihan yang signifikan sedangkan nilai yang terlalu besar dapat menyebabkan pembelajaran yang kurang optimal (Naushad et al., 2021).

Optimizer berguna untuk memperbarui bobot dan bias pada jaringan saraf selama pelatihan untuk meminimalkan kerugian atau *loss*. *Optimizer* yang paling umum digunakan untuk adalah *Stochastic Gradient Descent* (SGD), Adam dan RMSprop (Pardede & Rijal, 2025). *Stochastic Gradient Descent* (SGD) merupakan salah satu algoritma optimasi yang memperbarui parameter model berdasarkan satu sampel data yang dipilih secara acak pada tiap iterasi, hal ini yang menjadikan SGD lebih efisien dan dapat memungkinkan konvergensi yang lebih cepat, meskipun konvergensinya lebih fluktuatif. *Momentum* adalah algoritma untuk menekan

fluktuasi dan mempercepat serta memperlancar pembaruan konvergensi ketika *learning rate* kecil dan *gradient* kecil (Tian et al., 2023).

Weight decay merupakan teknik yang digunakan untuk mengontrol kompleksitas model dalam pembelajaran mesin, yang mendorong bobot model untuk tetap kecil selama proses pelatihan. *Weight decay* dapat mempengaruhi dinamika optimasi, yang dimana dapat meningkatkan regularisasi secara tidak langsung dalam algoritma *Stochastic Gradient Descent* (SGD) dan dapat menstabilkan proses pelatihan, oleh karena itu *weight decay* berfungsi untuk menyeimbangkan *trade off* bias yang mengarah pada penurunan kerugian pada proses pelatihan (Andriushchenko et al., 2024).



BAB III

METODE PENELITIAN

3.1 Waktu Penelitian

Penelitian ini dilaksanakan dari bulan Februari hingga Juni 2025 dengan data mangrove yang telah diperoleh melalui pengambilan foto secara manual dan langsung diberbagai tempat di Pulau Bintan seperti Dompak, Senggarang Besar dan Pengudang.

3.2 Jenis Penelitian

Jenis penelitian yang dilakukan adalah kuantitatif yang berfokus pada data dalam bentuk foto atau citral visual daun dan bunga mangrove. Data yang dikumpulkan akan digunakan untuk perhitungan sistem untuk mengidentifikasi dan klasifikasi. Data foto mangrove berbentuk RGB tersebut akan dianalisis secara numerik melalui *Faster R-CNN* yang melakukan analisis berbasis angka dan menghasilkan prediksi kuantitatif seperti tingkat akurasi prediksi dan klasifikasi.

3.3 Instrumen Penelitian

Penelitian yang dilakukan membutuhkan beragam instrumen yang mendukung, penelitian diantaranya *Roboflow*, *Google collaboratory*, bahasa pemrograman *Python* berserta *library Pytorch*, beserta perangkat keras (*hardware*) dengan spesifikasi sebagai berikut:

Operating System : Windows 10 Pro 64-bit


Processor : Intel(R) Core(TM) i3-7020U CPU @ 2.30GHz 2.30 GHz

Memory : 20.00 GB RAM

Graphics Card : Intel(R) HD Graphics 620 (128 MB)

3.4 Prosedur Penelitian

Penelitian ini bertujuan untuk mengukur akurasi dari metode *Faster R-CNN* yang menggunakan *backbone* dari arsitektur ResNet-50 FPN dalam mengidentifikasi dan mengklasifikasi jenis mangrove yang ada di Pulau Bintan. Alur tahapan yang diterapkan berupa studi literatur, pengumpulan dataset, *pre-processing* data, *training* model, evaluasi model, implementasi sistem. Dalam penelitian ini dataset akan dibagi menjadi 9 kelas. Alur penelitian yang penulis usulkan dapat dilihat pada gambar 3.1 dibawah ini :



Berikut adalah penjelasan untuk setiap alur pada penelitian yang diusulkan :

1. Studi Literatur, penulis mencari berbagai referensi dan tinjauan pustaka yang berkaitan dengan penelitian yang dilakukan. Referensi dapat berupa metode yang digunakan dalam melakukan identifikasi dan klasifikasi mangrove serta pemahaman tentang matriks evaluasi model.
2. Pengumpulan Dataset, dataset yang digunakan dari penelitian ini didapat dari hasil foto jenis mangrove di Pulau Bintan.
3. *Preprocessing* Dataset, tahap *preprocessing* dataset menggunakan bantuan aplikasi Roboflow dalam proses pelabelan foto jenis mangrove menggunakan *bounding box tool*, membagi dataset menjadi 70% untuk data latih, 20 % untuk data validasi dan 10% untuk data *testing*.

4. *Training* Model, setelah melalui proses *preprocessing* dataset maka dataset tersebut akan di latih dan di validasi dengan menggunakan algoritma *Faster R-CNN* dengan *backbone* ResNet-50, dilatih dan validasi menggunakan Google Collaboratory.
5. *Evaluasi* Model, setelah melalui tahapan *training* selanjutnya model akan mengukur kinerja model dalam mendekripsi dan mengklasifikasi objek menggunakan dataset *testing* 10% dan dataset baru yang belum dilihat model yang telah dilatih. *Evaluasi* model ini menggunakan matriks evaluasi mAP (*mean Average Precision*) dan AP (*Average Precision*). Hasil dari tahap ini model terbaik akan menghasilkan berbentuk file dengan format .pth. Setelah dari tahap ini model akan dilanjutkan kedalam proses implementasi sistem dengan membangun aplikasi mobile guna mengukur tingkat akurasi dan generalisasi model dalam mendekripsi data yang belum pernah lihat.
6. *Implementasi Sistem*, setelah model yang didapat sudah bekerja dengan baik, maka peneliti akan membuat sistem berbasis android dengan memanfaatkan model yang sudah di latih.

3.5 Studi Pustaka

Penelitian dilakukan melalui studi pustaka untuk memperoleh referensi atau informasi berupa landasan teoritis terkait penelitian terdahulu dari para ahli maupun penulis yang berkaitan dengan identifikasi dan klasifikasi jenis mangrove untuk memperoleh informasi mengenai implementasi *Faster R-CNN* dalam penelitian terkait. Studi Pustaka dilakukan dengan mengumpulkan jurnal penelitian internasional dan nasional sebagai sumber data dan referensi. Penelusuran bahan referensi juga berfokus pada topik penelitian pada penerapan metode *Faster R-CNN* dalam upaya mengidentifikasi dan mengklasifikasi jenis mangrove.

3.6 Pengumpulan Data

Proses pengumpulan data peneliti mengumpulkan data berupa foto mangrove berdasarkan daun dan bunga menggunakan kamera *smartphone* secara manual di Pulau Bintan dengan ditemani oleh ahli dibidang mangrove untuk mengenali jenis mangrove yang di ambil. Jumlah data yang berhasil dikumpulkan saat ini sebanyak 5400. Pada pengumpulan dataset ini, terdapat beberapa wilayah yang peneliti kunjungi di Pulau Bintan yaitu Senggarang Besar, Pengundang dan Dompak. Dengan data yang telah dikumpulkan seperti pada tabel 3.1 dibawah ini :

Tabel 3. 1 Distribusi Dataset

No	Kelas	Jumlah Data	Data Augmentasi	Data Validasi	Data Testing
			Training		
1	<i>Avicennia Lanata</i>	600	11338	1080	540
2	<i>Bruguiera cylindrica</i>	600	11338	1080	540
3	<i>Bruguiera gymnorhiza</i>	600	11338	1080	540
4	<i>Scyphiphora hydrophyllacea</i>	600	11338	1080	540
5	<i>Sonneratia Alba</i>	600	11338	1080	540
6	<i>Lumnitzera liitorea</i>	600	11338	1080	540
7	<i>Rhizophora apiculata</i>	600	11338	1080	540
8	<i>Rhizophora mucronata</i>	600	11338	1080	540
9	<i>Xylocarpus granatum</i>	600	11338	1080	540

Proses pengambilan data citra mangrove, digunakan spesifikasi perangkat dan ketentuan untuk memastikan kualitas dataset yang berkualitas. Adapun spesifikasi dan kondisi data yang diterapkan oleh peneliti sebagai berikut :


1. Peneliti menggunakan alat rekam citra menggunakan *smartphone* android Poco X 3PRO dengan resolusi kamera 48MP.

2. Perangkat *smartphone* yang digunakan harus di atur dengan pengaturan ratio 1:1 serta ISO yang diatur dalam mode otomatis (Auto) dengan manghasilkan citra dengan resolusi 3000 x 3000 piksel.
3. Sudut pengambilan gambar menggunakan *high angel* (dari atas) dan *front angle* (tampak depan).
4. Objek yang diambil dalam foto seperti daun dan bunga harus terlihat secara utuh dalam satu *frame* dengan hanya satu objek perfoto. Pengambilan gambar seperti setengah daun dan bunga tidak diperbolehkan.
5. Pencahayaan saat pengambilan gambar tidak terlalu gelap dan tidak terlalu terang.
6. Fokus utama dalam foto harus pada objek dengan jarak sekitar 7 hingga 15 cm (jika objek berukuran besar, jarak akan disesuaikan dengan ukuran *frame* kamera).
7. Objek dapat difoto dalam orientasi vertikal atau horizontal.
8. Objek yang difoto harus dalam kondisi sehat, muda dan tua. Tidak diperbolehkan mengambil data yang rusak atau bolong pada objek.

3.7 Analisis dan Perancangan

3.7.1 Analisis data

Penelitian untuk mengidentifikasi jenis mangrove yang ada di Pulau Bintan, tahap awal penelitian ini sebelum implementasi algoritma dan *preprocessing* serta *labeling* data adalah mengumpulkan data jenis mangrove berupa foto dengan mengambil bagian daun dan bunga pada mangrove. Setelah dataset telah terkumpul, sebelum data diolah untuk dideteksi dan klasifikasi menggunakan algoritma *Faster R-CNN*, dataset masuk ketahapan *preprocessing* data, data akan di *labeling* menjadi 9 kelas, kemudian data akan dibagi menjadi data *training* sebesar 70% data *validation* 20% dan data *testing* 10% menggunakan aplikasi Roboflow dengan fitur *bounding box tool*. Flowchart *preprocessing* serta *labeling* kelas menggunakan Roboflow dipaparkan sebagai berikut.



Gambar 3. 2 Flowchart *Labeling* Kelas Menggunakan Roboflow

Berikut adalah proses untuk melakukan *labeling* dataset di aplikasi Roboflow


:

1. Tahap yang paling awal adalah membuat halaman proyek di aplikasi Roboflow. Pada tahap ini pengguna diminta untuk memasukan nama proyek, kelas annotasi dan tipe proyek yaitu *object detection*.
2. Setelah berhasil membuat proyek, selanjutnya upload gambar dengan format yang didukung yaitu PNG, JPG, JPEG. Setelah berhasil upload pilih opsi simpan dan lanjutkan untuk melanjutkan.
3. Selanjutnya pilih opsi Mulai Manual *Labeling* untuk memulai proses *labeling* di aplikasi Roboflow.

4. Kemudian masuk kedalam halaman *labeling*, pilih menu *Bounding Box Tool* untuk melakukan *labeling*, kemudian setelah *labeling*, berikan nama kelas untuk objek yang telah di *labeling*.
5. Jika *labeling* sesuai, masuk ketahapan gambar yang sudah di *labeling*, masukan kedalam dataset.
6. Setelah itu dataset akan dibagi menjadi 70% data *training*, 20% data *validation* dan 10% data *testing*.
7. Setelah berhasil membagi dataset, selanjutnya pilih menu New Version, kemudian masuk ketahapan *preprocessing*, dimana terdapat beberapa menu seperti *auto-orient*, *resize* dan lain-lain. Peneliti menggunakan *auto-orient* dan *resize* 640 x 640.
8. Selanjutnya ketahapan, augmentasi, terdapat pilihan menu seperti *rotation*, *flip*, *brightness* dan lain lain. Peneliti menggunakan *rotation* 15 derajat, *flip horizontal*, *brightness* 15%.
9. Untuk menyelesaikan tahapan *preprocessing* pilih lanjut, kemudian akan dibuat dataset. Selanjutnya mendownload dataset yang telah dilabeling dengan format COCO JSON dan pilih opsi download show download code.

3.7.2 Perancangan Algoritma *Faster R-CNN* dan *Backbone ResNet 50 FPN*

Tahapan perancangan Algoritma *Faster R-CNN* dengan *backbone* ResNet-50 FPN sebagai ekstraksi fitur gambar untuk proses *training* dalam membuat sebuah model yang dapat mengidentifikasi dan klasifikasi. Proses ini memiliki beberapa tahapan yaitu ekstraksi fitur dengan menggunakan ResNet-50 FPN yang merupakan tahapan konvolusi dan *residual blocks*. Berikut adalah rancangan arsitektur ResNet-50:



Gambar 3. 3 Rancangan Arsitektur ResNet-50

- Image berukuran 640x640 piksel dengan *channel* RGB, sebagai inputan untuk masuk ketahapan proses *backbone* ResNet-50.
- Lapisan konvolusi 7x7 dengan *channel* fitur 64 dengan ukuran 320x320 dengan *kernel* (k) 7, *stride* (s) 2 dan *padding* (p) 3, dimana pada gambar rancangan Arsitektur ResNet-50, S adalah *stride* atau pergeseran posisi, K adalah *kernel* dan P adalah *padding*.
- *Max Pooling* dengan ukuran *kernel* 3 *stride* 2 dan *padding* 1 dengan output *channel*/fitur map berukuran 64x160x160
- *Residual Block* (C2) yang terdiri dari 3 *sub-layer* yaitu (konvolusi 1x1 dengan output *channel* 64x160x160 dengan *kernel* 1, *stride* 1 dan *padding* 0, konvolusi 3x3 dengan output *channel* 64x160x160 dengan


kernel 3x3, stride 1 dan padding 1, konvolusi 1x1 dengan output channel 256x160x160 dengan kernel 1, stride 1 dan padding 0

- *Residual Block (C3)* yang terdiri dari 4 *sub-layer* yaitu konvolusi 1x1 dengan output *channel* 128x160x160 dengan *kernel* 1, *stride* 1, *padding* 0, konvolusi 3x3 dengan output *channel* 128x80x80 dengan *kernel* 3, *stride* 2 dan *padding* 1, konvolusi 1x1 dengan output *channel* 512x80x80 dengan *kernel* 1, *stride* 1 dan *padding* 0.
- *Residual Block (C4)* yang terdiri dari 6 *sub-layer* yaitu konvolusi 1x1 dengan output *channel* 256x80x80 dengan *kernel* 1, *stride* 1 dan *padding* 0, konvolusi 3x3 dengan output 256x40x40 dengan *kernel* 3, *stride* 2, *padding* 1, konvolusi 1x1 dengan output *channel* 1024x40x40 dengan *kernel* 1, *stride* 1 dan *padding* 0.
- *Residual Block (C5)* yang terdiri dari 3 *sub-layer* yaitu konvolusi 1x1 dengan output *channel* 512x40x40 dengan *kernel* 1, *stride* 1 dan *padding* 0, konvolusi 3x3 dengan output *channel* 512x20x20 dengan *kernel* 3, *stride* 2 dan *padding* 1, konvolusi 1x1 dengan output *channel* 2048x20x20 dengan *kernel* 1, *stride* 1 dan *padding* 0.

Proses ekstraksi fitur ini, arsitektur ResNet-50 digunakan untuk menghasilkan fitur pada berbagai level kedalaman jaringan. Output dari lapisan C2 yang awalnya berukuran 320x320x64 akan dikonversi menjadi 160x160x256, sementara C3 menjadi 80x80x512, C4 menjadi 40x40x1024 dan C5 menjadi 20x20x2048. Fitur-fitur ini kemudian akan digunakan sebagai masukan kedalam *Feature Pyramid Network* (FPN), yang berfungsi untuk menyusun representasi fitur dalam berbagai skala. Representasi multi-skala ini sangat penting dalam meningkatkan kemampuan model dalam mendeteksi objek dengan ukuran dan bentuk yang bervariasi. Selanjutnya hasil dari FPN ini akan diteruskan ke *Region Proposal Network* (RPN) dalam arsitektur *Faster R-CNN*. Berikut penjelasan dari(Sun et al., 2024) terkait struktur FPN dalam arsitektur ResNet-50 berikut ini:


- Setiap lapisan yang dihasilkan dari ResNet-50 yaitu C2, C3, C4, C5 akan disesuaikan jumlah *channel* nya dan akan melakukan proses konvolusi 1x1.
- Kemudian proses dari hasil konvolusi 1x1, selanjutnya lapisan C2, C3, C4, C5 akan melakukan *upsampling*, kemudian dari hasil *upsampling* akan digabungkan (*fused*) yang bertujuan untuk memperbesar resolusi spasial fitur sambil menggabungkan isi dari lapisan yang lebih dalam.
- Setelah digabungkan, selanjutnya masuk ketahapan konvolusi 3x3, proses ini berguna untuk memperkaya informasi yang telah digabungkan dan menghasilkan P2 sampai P5.
- Setelah itu proses operasi *down sampling* atau *sub sampling* dengan menggunakan metode *max pooling* dari P5 akan menghasilkan P6. Dimana P6 ini merupakan informasi semantik yang sudah digabungkan di berbagai skala seperti objek yang sangat besar dan kecil. Peta Fitur P2, P3, P4, P5, P6 miliki informasi resolusi yang berbeda-beda.

Mendapatkan nilai fitur dari lapisan P2 hingga P6 yang dihasilkan dari proses FPN, selanjutnya nilai-nilai tersebut digunakan sebagai masukan untuk proses RPN pada algoritma *Faster R-CNN*, selanjutnya, hasil dari RPN diteruskan ketahapan *Fully Connected* untuk menghasilkan output berupa kelas objek (klasifikasi) dan koordinat lokasi objek yang dideteksi. Berikut adalah rancangan lengkap Algoritma *Faster R-CNN backbone* ResNet-50 FPN yang telah dijelaskan sebelumnya pada gambar 3.4 sebagai berikut ini :



Gambar 3. 4 Rancangan Faster R-CNN dengan ResNet-50 FPN

3.7.2.1 Training Model



Melakukan *training* model, kita perlu mengimport dataset yang telah kita *labeling* di Aplikasi Roboflow dalam format COCO. Setelah mengimport data, data harus melalui proses persiapan data. Data tersebut perlu dipisahkan dengan ketentuan seperti untuk *training* dan *validasi* dengan memisahkan *path* data berupa gambar dan *annotations coco json* dengan tepat sebelum lanjut ke proses selanjutnya.

```
train_dataset      =      get_coco_dataset("/content/Mangrove-Bintan-2/train",
"/content/Mangrove-Bintan-2/train/_annotations.coco.json")
val_dataset       =      get_coco_dataset("/content/Mangrove-Bintan-2/valid",
"/content/Mangrove-Bintan-2/valid/_annotations.coco.json")
```

Menginisialisasi dataset *training* dan *validasi* dengan mengatur *pathnya* sesuai dengan lokasi datasetnya. Langkah selanjutnya adalah persiapan data dimana dataset akan dimuat seperti gambar, anotasi dan mengubah gambar menjadi tensor pytorch saat diload.

```
class CocoTransform:
    def __call__(self, image, target):
        image = F.to_tensor(image)
        return image, target
```


Tahapan persiapan data sudah dilakukan, selanjutnya adalah proses inisialisasi *training* model. Dalam hal ini peneliti menggunakan bobot model *pretrained Faster R-CNN* dengan *backbone* ResNet-50 dan *Feature Pyramid Network* (FPN) yang telah di latih sebelumnya yang didapat dari dokumentasi resmi pytroch.

```
def get_model(num_classes):
    model = torchvision.models.detection.fasterrcnn_resnet50_fpn(weights='FasterRCNN_ResNet50_FPN_Weights.COCO_V1')
    in_features = model.roi_heads.box_predictor.cls_score.in_features
    model.roi_heads.box_predictor = FastRCNNPredictor(in_features,
                                                       num_classes)
    return model
```

Algoritma *Faster R-CNN* dengan arsitektur ResNet50 FPN diawali dengan proses konvolusi *layer* pada saat input gambar. Berikut proses perhitungan konvolusi *layer* menggunakan algoritma CNN dengan *input* gambar daun mangrove yang diubah ukuranya menjadi 7x7 *pixel* :

Langkah 1 : Input Gambar

1. Piksel citra gambar dengan 3 *channel* RGB (*Red*, *Green* dan *Blue*) diambil dari gambar dengan ukuran 7x7 seperti gambar dibawah ini :



Gambar 3. 6 Sample Citra Input

Langkah 2 : Convolutional Layer

2. Pada tahapan selanjutnya pada lapisan konvolusi ini, digunakan *kernel* berukuran 3x3. *Kernel* 3x3 diambil dari salah satu *kernel* Prewitt yang memiliki horizontal. Deteksi tepi prewitt adalah deteksi yang menggunakan dua *kernel* untuk mendeteksi yaitu deteksi tepi vertikal dan horizontal (Gijandren, 2020). Berikut adalah *kernel* 3x3 yang di representasikan dalam bentuk matriks :

Tabel 3. 2 Kernel 3x3

+1	+1	+1
0	0	0
-1	-1	-1

3. Selanjutnya menambahkan *padding* berupa nilai nol. *Padding* adalah parameter yang berfungsi untuk menentukan jumlah piksel yang bernilai nol yang ditambahkan tiap sisi dari inputan. *Padding* digunakan untuk membuat nilai keluaran sama dengan nilai inputan (Nugroho et al., 2023).
4. Langkah selanjutnya adalah melakukan perhitungan pada setiap *channel* dengan mengkalikan matriks *kernel* 3x3. Proses ini akan dilakukan secara berulang dengan pengeseran *kernel* sebanyak 2 *stride* di setiap saluran. Berikut adalah proses perhitungan :

0	0	0	0	0	0	0	0	0
0	228	227	229	233	236	239	238	0
0	218	219	224	229	234	235	233	0
0	221	216	224	230	228	231	229	0
0	214	216	223	226	231	228	223	0
0	202	205	211	216	219	219	213	0
0	193	198	194	196	205	207	204	0
0	187	185	184	188	195	200	204	0
0	0	0	0	0	0	0	0	0

+1	+1	+1
0	0	0
-1	-1	-1

Gambar 3. 7 Posisi 1 *Channel Red*

Langkah perhitungan proses konvolusi *channel red* dengan cara mengkalikan posisi *channel* dengan *kernel* 3x3 dengan pergeseran sebanyak 2 disetiap saluran dapat dijelaskan sebagai berikut:

- Posisi 1 : $(1 \times 0) + (1 \times 0) + (1 \times 0) + (0 \times 0) + (0 \times 228) + (0 \times 227) + (-1 \times 0) + (-1 \times 218) + (-1 \times 219) = -437$
- Posisi 2 : $(1 \times 0) + (1 \times 0) + (1 \times 0) + (0 \times 227) + (0 \times 229) + (0 \times 233) + (-1 \times 219) + (-1 \times 224) + (-1 \times 229) = -672$
- Posisi 3 : $(1 \times 0) + (1 \times 0) + (1 \times 0) + (0 \times 233) + (0 \times 236) + (0 \times 239) + (-1 \times 229) + (-1 \times 234) + (-1 \times 235) = -698$
- Posisi 4 : $(1 \times 0) + (1 \times 0) + (1 \times 0) + (0 \times 239) + (0 \times 238) + (0 \times 0) + (-1 \times 235) + (-1 \times 233) + (-1 \times 0) = -468$
- Posisi 5 : $(1 \times 0) + (1 \times 218) + (1 \times 219) + (0 \times 0) + (0 \times 221) + (0 \times 216) + (-1 \times 0) + (-1 \times 214) + (-1 \times 216) = 7$
- Posisi 6 : $(1 \times 219) + (1 \times 224) + (1 \times 229) + (0 \times 216) + (0 \times 224) + (0 \times 230) + (-1 \times 216) + (-1 \times 223) + (-1 \times 226) = 7$
- Posisi 7 : $(1 \times 229) + (1 \times 234) + (1 \times 235) + (0 \times 230) + (0 \times 228) + (0 \times 231) + (-1 \times 226) + (-1 \times 231) + (-1 \times 228) = 13$
- Posisi 8 : $(1 \times 235) + (1 \times 233) + (1 \times 0) + (0 \times 231) + (0 \times 229) + (0 \times 0) + (-1 \times 228) + (-1 \times 223) + (-1 \times 0) = 17$

- Posisi 9 : $(1x0) + (1x214) + (1x216) + (0x0) + (0x202) + (0x205) + (-1x0) + (-1x193) + (-1x198) = 39$
 - Posisi 10: $(1x216) + (1x223) + (1x226) + (0x205) + (0x211) + (0x216) + (-1x198) + (-1x194) + (-1x196) = 77$
 - Posisi 11: $(1x226) + (1x231) + (1x228) + (0x216) + (0x219) + (0x219) + (-1x196) + (-1x205) + (-1x207) = 77$
 - Posisi 12: $(1x228) + (1x223) + (1x0) + (0x219) + (0x213) + (0x0) + (-1x207) + (-1x204) + (-1x0) = 40$
 - Posisi 13: $(1x0) + (1x193) + (1x198) + (0x0) + (0x187) + (0x185) + (-1x0) + (-1x0) + (-1x0) = 391$
 - Posisi 14: $(1x198) + (1x194) + (1x196) + (0x185) + (0x184) + (0x188) + (-1x0) + (-1x0) + (-1x0) = 588$
 - Posisi 15: $(1x196) + (1x205) + (1x207) + (0x188) + (0x195) + (0x200) + (-1x0) + (-1x0) + (-1x0) = 608$
 - Posisi 16: $(1x207) + (1x204) + (1x0) + (0x200) + (0x204) + (0x0) + (-1x0) + (-1x0) + (-1x0) = 411$
5. Setelah melakukan tahap konvolusi pada tiap tiap *channel* RGB, kemudian didapatkan masing-masing nilai *red*, *green* dan *blue* seperti dibawah ini :

<i>Red</i>	-437	-672	-698	-468
	7	7	13	17
	39	77	77	40
	391	588	608	411

<i>Green</i>	-423	-651	-673	-450
	20	24	15	10
	42	64	37	4
	361	563	621	436

<i>Blue</i>	-385	-600	-634	-418
	51	68	66	50
	71	153	197	125
	263	379	371	243

Gambar 3. 8 Hasil Konvolusi *Channel Red*, *Green* dan *Blue*

6. Selanjutnya, setiap nilai dari *channel* yang sudah melalui tahapan perhitungan pada gambar akan dijumlahkan untuk mendapatkan output seperti berikut : $\text{Total} = \text{Red} + \text{Green} + \text{Blue}$.

-1245	-1923	-2005	-1336
78	99	94	77
152	294	311	168
1015	1530	1600	1090

Gambar 3. 9 Hasil Penjumlahan *Channel* RGB

7. Perhitungan selanjutnya adalah *activation ReLU*. ReLU adalah mengubah nilai negatif menjadi nol. Berikut adalah tahapan *activation ReLU* menggunakan persamaan (2.3) :

$$\text{Total} = \text{Red} + \text{Green} + \text{Blue}$$

$$\text{Hasil ReLU}$$

-1245	-1923	-2005	-1336
78	99	94	77
152	294	311	168
1015	1530	1600	1090

0	0	0	0
78	99	94	77
152	294	311	168
1015	1530	1600	1090

Gambar 3. 10 Hasil ReLU

8. Hasil dari tahapan ReLU, kemudian masuk ketahap *pooling*. Pada tahap *pooling* terdapat 2 teknik yaitu *Max Pooling* dan *Average Pooling*. Untuk perhitungan *pooling* menggunakan teknik *Max Pooling* dengan 2×2 *pooling* dan *stride* 2. Berikut tahapan *Max Pooling* dengan persamaan (2.4):

Hasil ReLU :

0	0	0	0
78	99	94	77
152	294	311	168
1015	1530	1600	1090

Hasil Max Pooling

99	

Hasil ReLU :

0	0	0	0
78	99	94	77
152	294	311	168
1015	1530	1600	1090

Hasil Max Pooling

99	94

Hasil ReLU :

0	0	0	0
78	99	94	77
152	294	311	168
1015	1530	1600	1090

Hasil Max Pooling

99	94
1530	

Hasil ReLU :

0	0	0	0
78	99	94	77
152	294	311	168
1015	1530	1600	1090

Hasil Max Pooling

99	94
1530	1600

Langkah 3: FPN + RPN

9. Hasil dari tahapan *Max Pooling* ini selanjutnya akan masuk ketahapan FPN, dimana pada tahap FPN, gambar akan diproses diberbagai skala agar mendapatkan hasil yang lebih detail pada objek besar dan kecil dalam gambar dan hasil dari proses FPN, kemudian masuk ketahapan *Region Proposal Network* (RPN). Pada tahapan ini akan menghasilkan sebuah *area region* yang mengandung objek dan koordinat dari objek tersebut. Terdapat bagian yaitu *box classification layer* yang berguna untuk menentukan apakah suatu wilayah memiliki objek atau tidak, kemudian *box regression layer* berguna untuk menghasilkan koordinat *bounding box* dari objek yang


dendetksi, untuk proses RPN dapat menggunakan persamaan (2.5), selanjutnya hasil dari RPN akan di proses pada lapisan *Fully Connected* atau *classifier* untuk mendapatkan hasil deteksi, proses ini menggunakan persamaan (2.11) dan (2.12).

3.7.2.2 Evaluasi Model

Tahap evaluasi model ini bertujuan untuk mengukur tingkat akurasi model dan generalisasi model dalam mendeteksi dan mengklasifikasi objek dengan menggunakan data *testing* sebanyak 10% dan data di luar dari data *testing* yang belum pernah dilihat pada saat model dilatih. Evaluasi model ini menggunakan matriks evaluasi *mean Average Precision* (mAP) dan *Average Precision* (AP) untuk mengukur efektivitas model secara keseluruhan maupun perkelas. Dari tahap ini akan menghasilkan sebuah model terbaik berbentuk file dengan format .pth. Kemudian dari model hasilkan akan digunakan untuk membangun sistem berbasis mobile untuk mengukur tingkat akurasi model dan generalisasi model terhadap data yang belum pernah dilihat sebelumnya.

3.7.3 Perancangan Aplikasi Mobile Identifikasi Mangrove di Pulau Bintan

Penelitian ini akan merancang sebuah aplikasi mobile untuk identifikasi dan klasifikasi jenis mangrove di Pulau Bintan. Perancangan aplikasi mobile ini akan menyajikan *flowchart* untuk memberikan gambaran terkait alur proses identifikasi dan klasifikasi jenis mangrove. Berikut *flowchart* perancangan aplikasi mobile untuk identifikasi dan deteksi jenis mangrove dapat dilihat di gambar berikut ini :



Gambar 3. 11 Flowchart Perancangan Sistem untuk Identifikasi Jenis Mangrove

Penjelasan dari proses *flowchart* Sistem untuk Identifikasi Jenis Mangrove di Pulau Bintan sebagai berikut ini :

1. Menu Aplikasi

Tahap ini pengguna mengakses aplikasi yang akan menampilkan antarmuka seperti *splashscreen* dan halaman *Home*, kemudian terdapat pilihan menu seperti ambil foto jika pengguna ingin mengidentifikasi langsung atau unggah gambar jika pengguna sudah memiliki gambar yang ingin di identifikasi, selanjutnya terdapat menu jenis mangrove berguna untuk melihat informasi detail dari jenis mangrove serta *developer* yang berguna untuk informasi tentang pembuat aplikasi ini.

2. Proses Identifikasi

Tahap ini, setelah pengguna mengambil foto atau mengunggah gambar, lanjut ketahapan proses identifikasi dimana gambar yang sudah di upload akan di resize menjadi ukuran 640x640 seperti ukuran gambar yang dilatih dimodel dan gambar yang dikirim format JPEG, JPG kemudian akan dikirimkan ke server dan akan dilakukan pengklasifikasian untuk mendeteksi objek dan memberikan *bounding box* serta label kelas untuk setiap objek dalam gambar.

3. Menampilkan Hasil Identifikasi

Proses klasifikasi selesai, *server* akan mengirim label yaitu nama jenis mangrove yang teridentifikasi, *box* merupakan koordinat objek hasil dari klasifikasi, dan *score* adalah keyakinan seberapa besar objek itu benar di identifikasi.

3.7.4 Rancangan Tampilan *User Interface* (UI)

1. Halaman *Splash Screen*

Aplikasi dibuka, maka akan menampilkan *Splash Screen* beberapa detik sebelum pengguna masuk ke halaman *Home*.



Gambar 3. 12 *User Interface* Halaman *Splash Screen*

2. Halaman *Home*

Halaman *Home* ini akan menampilkan fitur utama seperti ambil foto, unggah gambar, jenis mangrove dan *developer* aplikasi.



Gambar 3. 13 *User Interface* Halaman *Home* Screen

3. Halaman Ambil Foto

Halaman ambil foto, pengguna diminta untuk mengizinkan akses aplikasi untuk membuka kamera, kemudian mengambil foto menggunakan kamera bawaan dan pengguna dapat memcrop gambar agar sesuai dan fokus ke objeknya saja.



Gambar 3. 14 *User Interface* Halaman Ambil Foto

4. Halaman Unggah Gambar

Halaman unggah foto, sama seperti halaman ambil foto, pengguna diminta untuk mengizinkan akses aplikasi untuk membuka kamera, kemudian mengambil foto menggunakan kamera bawaan dan pengguna dapat memcrop gambar agar sesuai dan fokus ke objeknya saja.



Gambar 3. 15 *User Interface* Halaman Unggah Gambar

5. Halaman *Pop Up* Aturan

Tahap ini, ketika pengguna masuk ke halaman ambil foto dan unggah gambar, pengguna akan mendapatkan sebuah *pop up* tentang aturan gambar agar dapat teridentifikasi dengan baik oleh model sistem, jika gambar tidak sesuai yang diharapkan oleh sistem, bisa saja gambar tidak dapat terdeteksi dengan baik.



Gambar 3. 16 *User Interface* Halaman *Pop Up* Aturan

6. Halaman Validasi Gambar

Diberikan akses untuk mengambil dan mengunggah foto selanjutnya ke tahapan validasi gambar, apakah gambar sesuai yang kita inginkan dan jika ingin mengambil ulang atau upload gambarnya belum berhasil silahkan pilih menu ambil ulang.



Gambar 3. 17 *User Interface* Halaman Validasi Gambar

7. Halaman Output Prediksi

Pengguna mengikuti aturan dalam pengambilan foto pada suatu objek yang ingin diidentifikasi, serta memberikan izin untuk dapat mengakses kamera dan sudah memvalidasi gambar apakah sesuai dengan yang kita foto, selanjutnya tunggu beberapa detik untuk melihat hasil dari identifikasi mangrove.



Gambar 3. 18 *User Interface* Halaman Ouput Prediksi

8. Halaman Jenis Mangrove

Menu jenis mangrove, pengguna dapat melihat berbagai jenis mangrove yang diteliti serta bisa melihat gambar, nama-nama jenis mangrove serta deskripsi singkat beserta tombol detail jika ingin melihat lebih detail terkait infomasi jenis mangrove dengan jenis tertentu.



Gambar 3. 19 *User Interface* Halaman Jenis Mangrove

9. Halaman Detail Mangrove


Halaman detail mangrove ini menampilkan sebuah informasi detail tentang jenis mangrove tertentu seperti nama jenis mangrove, foto daun mangrove, deskripsi, ekologi, manfaat, penyebaran dan gambar bunga dari suatu jenis mangrove.



Gambar 3. 20 *User Interface* Halaman Detail Jenis Mangrove

10. Halaman Pengembang

Halaman pengembang ini menampilkan informasi tentang pembuat atau pengembang pada aplikasi MangroveID ini.



Gambar 3. 21 *User Interface Halaman Developer*

BAB IV

HASIL DAN PEMBAHASAN

4.1 Lingkungan Uji Coba

Lingkungan pengujian ini akan dilakukan meliputi beberapa aspek perangkat lunak, perangkat keras, serta beberapa aspek dan kriteria pengujian lainnya seperti sampel data yang digunakan dan jumlah pengujian yang dilakukan. Lingkungan pengujian tersebut dijelaskan sebagai berikut:

Tabel 4. 1 Spesifikasi Lingkungan Uji Coba

Perangkat Keras	
CPU	Windows 10 Pro 64-bit
RAM	20 GB
Perangkat Lunak	
Operating System	Intel Core i3
Lingkungan Pengkodean	Google Colab Pro
GPU Runtime Google Colab	A100 GPU
Training Runtime Google Colab	GPU RAM 40 GB
Pengujian Runtime	CPU RAM Sistem
Kriteria Pengujian	
Ukuran Gambar	1:1
Sample Data	40 Objek Masing-Masing Kelas, 40 Data Bukan Mangrove.
Jumlah Pengujian	400 Kali Pengujian

4.2 Pelatihan dan Metrik Evaluasi performa Algoritma Faster R-CNN

Proses pelatihan yang dilakukan menggunakan model yang telah di latih sebelumnya dengan data latih sebanyak 70% dataset *training*. Selanjutnya, model akan melakukan evaluasi performa model dari dataset validasi sebanyak 20% dari masing-masing iterasi dengan menggunakan metrik evaluasi *Mean Average Precision* (mAP) dan *Average Precision* (AP). Pada proses pelatihan ini melibatkan beberapa parameter yang digunakan dalam proses pembelajaran model dan pengoptimalkan performa model untuk mendeteksi dan mengklasifikasi objek. Berikut parameter yang digunakan untuk pelatihan :


Tabel 4. 2 Parameter yang digunakan

Parameter	Nilai Parameter
<i>Optimizer</i>	SGD
<i>Learning Rate</i>	0,01
<i>Momentum</i>	0,9
<i>Weight Decay</i>	0,0005
<i>Epoch</i>	30
<i>Batch size</i>	4, 8, 16

4.2.1 Pelatihan Algoritma Faster R-CNN *Batch size 4*

Proses pelatihan ini, akan menggunakan model dari algoritma *Faster R-CNN* dengan menggunakan *batch size* 4. Pelatihan ini akan menggunakan parameter yang akan digunakan seperti *optimizer*, *learning rate*, *momentum* dan *wieght decay* seperti pada tabel 4.2. Pada tahap ini, peneliti melakukan pelatihan sebanyak 30 *epoch* dengan total dataset yang telah di augmentasi untuk dataset *training* sebesar 11338 gambar, dataset validasi sebesar 1080 gambar dan dataset *testing* sebesar 540 gambar dengan menghabiskan waktu selama *training* 5 jam 30 menit, dimana hasil *training loss* yang didapat dilihat pada gambar 4.1 yang menunjukkan penurunan yang signifikan pada awal pelatihan. Dari data grafik, pada *epoch* 1, model masih dalam proses pengenalan namun model dapat belajar dengan baik dari data,


selanjutnya pada *epoch* 2 hingga 8 terjadi penurunan yang tajam hal ini menunjukkan bahwa model sangat baik dalam mengenal pola-pola pada data sehingga model dapat lebih cepat belajar. Pada *epoch* 9 hingga 11, model mengalami penurun sedikit, menandakan bahwa model sudah mendekati kondisi konvergen, dimana pada kondisi ini model mencapai titik dimana parameter-parameter tidak lagi berubah secara signifikan dari satu iterasi ke iterasi berikutnya. Setelah hampir mencapai kondisi *konvergen*, pada *epoch* 12 hingga 30 *loss* stabil hingga akhir pelatihan, yang merepresentasikan bahwa model telah berhasil dalam proses pembelajaran.



Gambar 4. 1 *Training Loss Epoch 30 Batch size 4*

Hasil dari evaluasi model *Faster R-CNN* pada *epoch* 30 dengan *batch size* 4 dengan menggunakan metrik evaluasi *mean Average Precision* (mAP) dan *Average Precision* (AP). Pada metrik evaluasi *mean Average Precision* (mAP) dengan IoU 0.50:0.95 menunjukkan performa yang baik dapat dilihat pada gambar 4.2. Secara keseluruhan, model dengan *threshold* IoU 0.50:0.95 mencapai akurasi mAP terbaik sebesar 62,59%, yang menunjukkan bahwa tingkat akurasi model dalam mendeteksi macam-macam jenis mangrove pada data validasi. Grafik pada gambar 4.2 terlihat bahwa model sudah mengalami peningkatan akurasi pada *epoch* 1 hingga 2, namun pada *epoch* 3 model mengambil penurunan akurasi dari akurasi

56,20% pada *epoch* 2 menjadi 55,20% pada *epoch* 3, peneliti berpendapat hal ini terjadi karena beberapa kelas masih dalam proses pengenalan pola dan struktur pada daun yang memiliki struktur dan bentuk yang hampir mirip di beberapa kelas, namun untuk kelas yang sedikit berbeda dari segi struktur dan bentuk sudah baik dalam proses pembelajaran. Selanjutnya pada *epoch* 4 hingga 30 model sudah sangat baik, stabil dan berhasil dalam proses pembelajarannya.




Metrik evaluasi *Average Precision* (AP) dengan IoU 0,5 menunjukkan performa yang sangat baik yang dapat dilihat pada gambar 4.3 dan tabel 4.3 Dari hasil model dengan *threshold* IoU 0,5 per-kelas. Model mengenal objek dengan akurasi tinggi pada kelas *Sonneratia Alba* sebesar 99,00%. Sementara untuk kelas *Scyphiphora hydrophyllacea* memiliki AP sebesar 97,87%, *Avicennia Lanata* memiliki AP 95,61%, *Bruguiera gymnorhiza* memiliki AP sebesar 97,72%, *Lumnitzera liitorea* memiliki AP sebesar 96,46%, *Rhizophora apiculata* sebesar 95,42%, *Rhizophora mucronata* sebesar 93,19% dan untuk masing masing kelas *Bruguiera cylindrica* dan *Xylocarpus granatum* memiliki AP sebesar 82,27% dan 89,99%. Pada grafik AP 0,5 pada gambar 4.3, terlihat bahwa model mengalami pola naik-turun pada *epoch* 1 hingga *epoch* 5, dimana hal ini terjadi karena disebabkan performa model dalam mengenali masing masing kelas memiliki perbedaan, dimana ketika performa model disuatu kelas meningkat, maka secara bersama salah

satu kelas mengalami penurunan. Seperti yang terjadi pada kelas *Avicennia Lanata* dan *Xylocarpus granatum* yang mengalami pola naik-turun yang cukup signifikan hal ini terjadi karena bentuk atau pola visual dari 2 kelas tersebut sedikit sama, dibandingkan dengan kelas lain yang memiliki bentuk dan ciri pola visual yang konsisten. Secara keseluruhan, dilanjutkan pada epoch 6 hingga 30, terdapat 2 kelas yang nilai AP nya rendah seperti *Bruguiera cylindrica* dan *Xylocapus granatum*, peneliti berasumsi hal ini terjadi karena warna serta kondisi cahaya dalam pengambilan fotonya ditempat yang sedikit lebih gelap, dikarenakan lingkungan tempat tanaman mangrove hidup tersebut memiliki lebih banyak naungan atau bayangan sehingga warna daunnya tidak mencolok dengan baik.

Tabel 4. 3 Nilai AP IoU=0.5 Epoch 30 Batch size 4

Jenis AP (0.5)	Nilai AP
AP <i>Avicennia Lanata</i>	95,61%
AP <i>Bruguiera cylindrica</i>	82,27%
AP <i>Bruguiera gymnorhiza</i>	97,72%
AP <i>Lumnitzera liitorea</i>	96,46%
AP <i>Rhizophora apiculata</i>	95,42%
AP <i>Rhizophora mucronata</i>	93,19%
AP <i>Scyphiphora hydrophyllacea</i>	97,87%
AP <i>Sonneratia Alba</i>	99,00%
AP <i>Xylocarpus granatum</i>	89,99%




Gambar 4. 3 Grafik Validasi AP IoU=0.50 Epoch 30 Batch size 4

4.2.2 Pelatihan Algoritma Faster R-CNN Batch size 8

Proses pelatihan ini, akan menggunakan model dari algoritma *Faster R-CNN* dengan menggunakan *batch size* 8. Pelatihan ini akan menggunakan parameter yang akan digunakan seperti *optimizer*, *learning rate*, *momentum* dan *weight decay* seperti pada tabel 4.2. Pada tahap ini, peneliti melakukan pelatihan sebanyak 30 *epoch* dengan total dataset yang telah di augmentasi untuk dataset *training* sebesar 11338 gambar, dataset validasi sebesar 1080 gambar dan dataset *testing* sebesar 540 gambar dengan menghabiskan waktu selama *training* 5 jam 15 menit, dimana hasil *training loss* yang didapat dilihat pada gambar 4.4 yang menunjukkan penurunan yang tajam pada awal pelatihan. Pada awal pelatihan dimulai pada nilai *loss* yaitu 0,155 pada *epoch* 1, hal ini terjadi karena model masih tahap awal dalam belajar mengenai pola data yang digunakan. Selanjutnya pada *epoch* 1 hingga 7 mengalami penurunan yang sangat tajam sehingga nilai *loss* menjadi 0,004 lebih baik dari sebelumnya pada *epoch* 1. Hal ini menunjukkan bahwa model sangat baik dan cepat dalam memahami pola dalam data. Setelah itu pada *epoch* 8 hingga 30 grafik mulai


mendarat dan sudah mulai konvergen sampai model telah mencapai stabil dari nilai lossnya.



Gambar 4. 4 Training Loss Epoch 30 Batch size 8

Hasil dari evaluasi model *Faster R-CNN* pada *epoch* 30 dengan *batch size* 8 dengan menggunakan metrik evaluasi *mean Average Precision* (mAP) dan *Average Precision* (AP). Pada metrik evaluasi *mean Average Precision* (mAP) dengan IoU 0.50:0.95 menunjukkan performa yang baik dapat dilihat pada gambar 4.5. Secara keseluruhan, model dengan *threshold* IoU 0.50:0.95 mencapai akurasi mAP terbaik sebesar 61,93%, yang menunjukkan bahwa tingkat akurasi model dalam mendeteksi macam-macam jenis mangrove pada data validasi. Grafik pada gambar 4.5 terlihat bahwa model sudah mengalami peningkatan akurasi yang signifikan pada *epoch* 1 hingga *epoch* ke 5 dengan capai akurasi mAP sebesar 62,12% hal ini menunjukkan bahwa model sudah baik dalam mempelajari pola pada data, namun pada *epoch* 6 model mengalami penurunan dari 62,12% menjadi 60,15%. Penurunan ini disebabkan oleh degradasi akurasi pada salah satu kelas yang mengakibatkan ketidakseimbangan distribusi mAP antara kelas. Selain itu penggunaan *batch size* yang besar yaitu *batch size* 8, yang menyebabkan *noise gradient* yang lebih tinggi sehingga menghambat proses konvergensi. Setelah penyesuaian tersebut, pada *epoch* selanjutnya hingga *epoch* 30, model berhasil

mencapai stabilitas performa dengan loss yang konsisten menurun dan akurasi mAP yang lebih merata dan menandakan proses pembelajaran berhasil.



Gambar 4. 5 Grafik Validasi mAP IoU=0.5:0.95 Epoch 30 Batch size 8


Selanjutnya pada metrik evaluasi *Average Precision* (AP) dengan IoU 0.5 menunjukkan performa yang sangat baik yang dapat dilihat pada gambar 4.6 dan tabel 4.4. Dari hasil model dengan *threshold* IoU 0.5 per-kelas. Model mengenal objek dengan akurasi tinggi pada kelas *Scyphiphora hydrophyllacea* memiliki AP sebesar 99,42%. Sementara untuk kelas *Avicennia Lanata* memiliki AP sebesar 95,61%, *Bruguiera cylindrica* memiliki AP sebesar 80,60%, *Bruguiera gymnorhiza* memiliki 96,99% memiliki AP sebesar 97,72%, *Lumnitzera liitorea* memiliki AP sebesar 97,49%, *Rhizophora apiculata* memiliki AP sebesar 96,37%, *Rhizophora mucronata* memiliki AP sebesar 92,12%, *Sonneratia Alba* memiliki AP sebesar 99,09% dan *Xylocarpus granatum* 89,57%. Pada grafik AP 0.5 pada gambar 4.6, pada tahap awal pelatihan performa model pada epoch 1 hingga 5 menunjukkan bahwa model masih dalam proses pembelajaran pola-pola dimana terdapat pola naik-turun seperti pada kelas *Xylocarpus granatum* dimana, model masih mempelajari pola pada kelas ini, namun kelas-kelas lain mengalami penaikan yang stabil. Namun setelah itu, grafik menunjukkan bahwa model sudah mendekati

kondisi konvergen dimana nilai AP sudah konsisten hingga model mencapai titik stabil hingga epoch 30.

Tabel 4. 4 Nilai AP IoU=0.5 Epoch 30 Batch size 8

Jenis AP (0.5)	Nilai AP
AP <i>Avicennia Lanata</i>	95,61%
AP <i>Bruguiera cylindrica</i>	80,60%
AP <i>Bruguiera gymnorhiza</i>	96,99%
AP <i>Lumnitzera liitorea</i>	97,49%
AP <i>Rhizophora apiculata</i>	96,37%
AP <i>Rhizophora mucronata</i>	92,12%
AP <i>Scyphiphora hydrophyllacea</i>	99,42%
AP <i>Sonneratia Alba</i>	99,09%
AP <i>Xylocarpus granatum</i>	89,57%






Gambar 4. 6 Grafik Validasi AP IoU=0.50 Epoch 30 Batch size 8


4.2.3 Pelatihan Algoritma Faster RCNN **Batch size 16**

Proses pelatihan ini, akan menggunakan model dari algoritma Faster R-CNN dengan menggunakan *batch size* 16. Pelatihan ini akan menggunakan parameter yang akan digunakan seperti *optimizer*, *learning rate*, *momentum* dan *weight decay* seperti pada tabel 4.2. Pada tahap ini, peneliti melakukan pelatihan sebanyak 30 *epoch* dengan total dataset yang telah di augmentasi untuk dataset *training* sebesar 11338 gambar, dataset validasi sebesar 1080 gambar dan dataset *testing* sebesar 540 gambar dengan menghabiskan waktu selama *training* 10 jam, dimana berdasarkan hasil *training loss* yang didapat dilihat pada gambar 4.7 yang menunjukkan penurunan yang sangat tajam dari awal pelatihan *epoch* 1 yang *training loss* bernilai 0,1687 hingga *epoch* ke 7 yang *training loss* bernilai 61,19%, hal ini karena model sangat efektif dan cepat mengenali pola pada data yang diberikan, sehingga penurunan *training loss* yang sangat signifikan. Setelah proses itu, grafik mulai mendatar yang mengindikasikan model telah mencapai kondisi konvergen dengan perubahan *loss* yang sangat kecil dimana sudah mencapai titik stabil dalam perubahan nilai *loss* menjadi sangat kecil hingga *epoch* 30.



Gambar 4. 7 Training Loss Epoch 30 Batch size 16

Hasil dari evaluasi model Faster R-CNN pada *epoch* 30 dengan *batch size* 16 dengan menggunakan metrik evaluasi mean *Average Precision* (mAP) dan *Average Precision* (AP). Pada metrik evaluasi *mean Average Precision* (mAP) dengan IoU 0.50:0.95 menunjukkan performa yang baik dapat dilihat pada gambar 4.8. Secara keseluruhan, model dengan *threshold* IoU 0.50:0.95 mencapai akurasi mAP terbaik sebesar 61,19%, yang menunjukkan bahwa tingkat akurasi model dalam mendeteksi macam-macam jenis mangrove pada data validasi. Grafik pada gambar 4.8 terlihat bahwa saat awal pelatihan model sangat baik mempelajari pola pada data yang telah diberikan pada *epoch* 1 hingga 3, namun setelah itu dari *epoch* 4 hingga *epoch* 11 mengalami pola naik turun, hal ini terjadi karena penggunaan *batch size* yang besar yaitu 16, sehingga menyebabkan *noise gradient* menjadi tinggi serta disebabkan performa model dalam mengenali masing masing kelas memiliki perbedaan dimana ketika performa model disuatu kelas meningkat, maka secara bersamaan salah satu kelas mengalami penurunan. Setelah proses itu, pada *epoch* selanjutnya model berhasil mencapai stabil perfoma dengan akurasi mAP yang lebih konsisten yang mengindikasikan pembelajaran berjalan dengan baik.




Gambar 4. 8 Grafik Validasi mAP IoU=0.5:0.95 Epoch 30 Batch size 16

Selanjutnya pada metrik evaluasi *Average Precision* (AP) dengan IoU 0.5 menunjukkan performa yang sangat baik yang dapat dilihat pada gambar 4.9 dan tabel 4.5. Dari hasil model dengan *threshold* IoU 0.5 per-kelas. Model mengenal objek dengan akurasi tinggi pada kelas *Sonneratia Alba* memiliki AP sebesar 98,64%. Sementara untuk kelas *Avicennia Lanata* memiliki AP sebesar 95,78%, *Bruguiera cylindrica* memiliki AP sebesar 79,50%, *Bruguiera gymnorhiza* memiliki AP sebesar 96,64%, *Lumnitzera littorea* memiliki AP sebesar 97,34%, *Rhizophora apiculata* memiliki AP sebesar 93,70%, *Rhizophora mucronata* memiliki AP sebesar 90,08%, *Scyphiphora hydrophyllacea* memiliki AP sebesar 98,22% dan *Xylocarpus granatum* memiliki AP sebesar 86,37%. Pada grafik AP 0.5 pada gambar 4.9, pada tahap awal pelatihan model masih dalam proses mengenali pola, terdapat sedikit terjadi pola naik turun yang terjadi hanya di salah satu kelas yaitu *Bruguiera cylindrica*, dimana model masih mempelajari pola pada kelas ini, dibandingkan kelas lain, yang sangat stabil kenaikan akurasinya yang terjadi di *epoch* 1 hingga 11, Setelah itu model mengindikasikan telah mencapai kondisi stabil dan konsisten sampai *epoch* 30.

Tabel 4. 5 Nilai AP IoU=0.5 Epoch 30 Batch size 16

Jenis AP (0.5)	Nilai AP
AP <i>Avicennia Lanata</i>	95,78%
AP <i>Bruguiera cylindrica</i>	79,50%
AP <i>Bruguiera gymnorhiza</i>	96,64%
AP <i>Lumnitzera liitorea</i>	97,34%
AP <i>Rhizophora apiculata</i>	93,70%
AP <i>Rhizophora mucronata</i>	90,08%
AP <i>Scyphiphora hydrophyllacea</i>	98,22%
AP <i>Sonneratia Alba</i>	98,64%
AP <i>Xylocarpus granatum</i>	86,37%



Gambar 4. 9 Grafik Validasi AP IoU=0.50 Epoch 30 Batch size 16

4.2.4 Hasil Keseluruhan Pelatihan Model

Secara keseluruhan dari beberapa percobaan pelatihan model dengan *batch size* 4, 8 dan 16, menunjukkan bahwa perlatihan dengan *batch size* 4 memiliki nilai mAP dan AP lebih baik dibandingkan dengan *batch size* 8 dan 16 dengan waktu pelatihan 5 jam 30 menit. Namun pada pelatihan *batch size* 8 model berjalan lebih efisien dibandingkan dengan *batch size* 4 dengan memakan waktu pelatihan yaitu 5 jam 15 menit. Pada *batch size* 8 terdapat fluktuasi di beberapa *epoch* awal dikarenakan ketidakseimbangan *noise gradient* yang mempengaruhi performa model, dalam hal ini, *batch size* 8 memang dapat mempercepat proses pelatihan namun sedikit menurun dari segi performa model dibandingkan dengan *batch size* 4.

Batch size 16 memiliki performa yang lebih rendah dibandingkan dengan *batch size* 4 dan 8, yang dimana memakan waktu pelatihan yang sangat lama yaitu 10 jam dibandingkan dengan *batch size* 4 dan *batch size* 8, hal ini bisa terjadi karena peneliti berpendapat bahwa peningkatan ukuran *batch size* yang sangat besar menyebabkan kompleksitas komputasi GPU meningkat secara signifikan, dikarenakan arsitektur *Faster R-CNN* memiliki dua tahapan pemrosesan yaitu RPN dan *Fast R-CNN* yang memerlukan daya dan waktu komputasi yang besar dan dari segi aspek data yang besar dengan menggunakan augmentasi jadi total dataset yang digunakan seluruhnya sebanyak 12958 data yang telah di bagi menjadi *training*, validasi dan *testing*, meskipun peneliti telah menggunakan GPU A100 yang merupakan GPU tingkat tinggi yang disediakan dari Google Colaboratory Pro, namun tidak sepenuhnya dapat mengurangi tantangan efisiensi yang muncul dari model arsitektur *Faster R-CNN* khususnya dalam percobaan *batch size* 16. Dengan demikian, untuk pengujian lebih lanjut akan menggunakan hasil pelatihan model dengan *batch size* 4 untuk mengukur tingkat akurasi data jenis mangrove yang baru pada masing-masing kelas mangrove. Pada tabel 4.6 merupakan hasil pelatihan terbaik, berikut merupakan hasil keseluruhan pelatihan pada tiap *batch size* yang dapat dilihat pada tabel 4.6 hingga 4.8 sebagai berikut:

Tabel 4. 6 Hasil Pelatihan Terbaik Pada Batch size 4 Epoch 30

Kelas	Nilai AP Perkelas (IoU= 0.5)	Nilai MAP Keseluruhan Kelas (IoU=0.5:0.95)
<i>Avicennia Lanata</i>	95,61%	62,59%
<i>Bruguiera cylindrica</i>	82,27%	
<i>Bruguiera gymnorhiza</i>	97,72%	
<i>Lumnitzera liitorea</i>	96,46%	
<i>Rhizophora apiculata</i>	95,42%	
<i>Rhizophora mucronata</i>	93,19%	
<i>Scyphiphora hydrophyllacea</i>	97,87%	
<i>Sonneratia Alba</i>	99,00%	
<i>Xylocarpus granatum</i>	89,99%	

Tabel 4. 7 Hasil Pelatihan Batch size 8 Epoch 30

Kelas	Nilai AP Perkelas (IoU= 0.5)	Nilai MAP Keseluruhan Kelas (IoU=0.5:0.95)
<i>Avicennia Lanata</i>	95,61%	61,93%
<i>Bruguiera cylindrica</i>	80,60%	
<i>Bruguiera gymnorhiza</i>	96,99%	
<i>Lumnitzera liitorea</i>	97,49%	
<i>Rhizophora apiculata</i>	96,37%	
<i>Rhizophora mucronata</i>	92,12%	
<i>Scyphiphora hydrophyllacea</i>	99,42%	
<i>Sonneratia Alba</i>	99,09%	
<i>Xylocarpus granatum</i>	89,57%	

Tabel 4. 8 Hasil Pelatihan *Batch size 16 Epoch 30*

Kelas	Nilai AP Perkelas (IoU= 0.5)	Nilai MAP Keseluruhan Kelas (IoU=0.5:0.95)
<i>Avicennia Lanata</i>	95,78%	
<i>Bruguiera cylindrica</i>	79,50%	
<i>Bruguiera gymnorhiza</i>	96,64%	
<i>Lumnitzera littorea</i>	97,34%	
<i>Rhizophora apiculata</i>	93,70%	
<i>Rhizophora mucronata</i>	90,08%	
<i>Scyphiphora hydrophyllacea</i>	98,22%	
<i>Sonneratia Alba</i>	98,64%	
<i>Xylocarpus granatum</i>	86,37%	
		61,19%

4.3 Pengujian dan Analisis Akurasi Model *Faster R-CNN*

Tahap pengujian ini, peneliti melakukan pengujian dengan data baru yang belum pernah dilihat sama sekali oleh model sebelumnya. Pengujian dilakukan dengan menggunakan model pada pelatihan *epoch 30 batch size 4* dikarenakan model pelatihan tersebut lebih bagus dari pada model dalam pelatihan lainnya. Tahap pengujian dilakukan pada 40 objek pada masing-masing kelas, 40 objek *undefined label* atau kelas bukan kategori mangrove.

4.3.1 Pengujian Akurasi Pada Dataset *One Label*

Tabel 4. 9 Pengujian Dataset *Avicennia Lanata*

Pengujian Ke-	Hasil Deteksi (Jumlah Objek)	Pengujian Ke-	Hasil Deteksi (Jumlah Objek)
Pengujian 1	Benar 1 (1)	Pengujian 21	Benar 1 (1)
Pengujian 2	Benar 1 (1)	Pengujian 22	Benar 1 (1)
Pengujian 3	Benar 1 (1)	Pengujian 23	Benar 1 (1)
Pengujian 4	Benar 1 (1)	Pengujian 24	Benar 1 (1)
Pengujian 5	Benar 1 (1)	Pengujian 25	Benar 1 (1)
Pengujian 6	Benar 2 (2)	Pengujian 26	Benar 1 (1)
Pengujian 7	Benar 1 (1)	Pengujian 27	Benar 1 (1)
Pengujian 8	Benar 1 (1)	Pengujian 28	Benar 1 (1)
Pengujian 9	Salah 1 (1)	Pengujian 29	Salah 1 (1)
Pengujian 10	Benar 1 Salah 1 (2)	Pengujian 30	Benar 1 (1)
Pengujian 11	Benar 1 (1)	Pengujian 31	Benar 2 (2)
Pengujian 12	Benar 1 (1)	Pengujian 32	Benar 1 (1)
Pengujian 13	Benar 1 (1)	Pengujian 33	Benar 1 (1)
Pengujian 14	Benar 1 (1)	Pengujian 34	Benar 1 (1)
Pengujian 15	Benar 1 (1)	Pengujian 35	Benar 1 (1)
Pengujian 16	Salah 1 (1)	Pengujian 36	Benar 1 (1)
Pengujian 17	Benar 1 (1)	Pengujian 37	Benar 1 (1)
Pengujian 18	Benar 1 (1)	Pengujian 38	Benar 1 (1)
Pengujian 19	Benar 2 (2)	Pengujian 39	Benar 1 (1)
Pengujian 20	Benar 1 (1)	Pengujian 40	Benar 1 (1)
Total		Benar	40
		Salah	4

Tabel 4. 10 Pengujian Dataset *Lumnitzera liitorea*

Pengujian Ke-	Hasil Deteksi (Jumlah Objek)	Pengujian Ke-	Hasil Deteksi (Jumlah Objek)
Pengujian 1	Benar 1 (1)	Pengujian 21	Benar 1 (1)
Pengujian 2	Benar 1 (1)	Pengujian 22	Benar 1 (1)
Pengujian 3	Benar 1 (1)	Pengujian 23	Benar 1 (1)
Pengujian 4	Benar 1 (1)	Pengujian 24	Benar 1 (1)
Pengujian 5	Benar 2 (2)	Pengujian 25	Benar 1 (1)
Pengujian 6	Benar 1 (1)	Pengujian 26	Benar 1 (1)
Pengujian 7	Benar 2 (2)	Pengujian 27	Benar 1 (1)
Pengujian 8	Benar 1 (1)	Pengujian 28	Benar 1 (1)
Pengujian 9	Benar 1 (1)	Pengujian 29	Benar 1 (1)
Pengujian 10	Benar 1 (1)	Pengujian 30	Benar 1 (1)
Pengujian 11	Benar 2 (2)	Pengujian 31	Benar 1 (1)
Pengujian 12	Benar 1 (1)	Pengujian 32	Benar 1 (1)
Pengujian 13	Benar 1 (1)	Pengujian 33	Benar 1 (1)
Pengujian 14	Benar 1 (1)	Pengujian 34	Benar 1 (1)
Pengujian 15	Benar 1 (1)	Pengujian 35	Benar 2 (2)
Pengujian 16	Benar 1 (1)	Pengujian 36	Benar 1 (1)
Pengujian 17	Benar 1 (1)	Pengujian 37	Benar 1 (1)
Pengujian 18	Benar 1 (1)	Pengujian 38	Benar 3 (3)
Pengujian 19	Benar 1 (1)	Pengujian 39	Benar 1 (1)
Pengujian 20	Benar 1 (1)	Pengujian 40	Benar 2 (2)
Total		Benar	47
		Salah	0

Tabel 4. 11 Pengujian Dataset *Sonneratia Alba*

Pengujian Ke-	Hasil Deteksi (Jumlah Objek)	Pengujian Ke-	Hasil Deteksi (Jumlah Objek)
Pengujian 1	Benar 1 (1)	Pengujian 21	Benar 1 (1)
Pengujian 2	Benar 1 (1)	Pengujian 22	Benar 1 (1)
Pengujian 3	Benar 1 (1)	Pengujian 23	Benar 1 (1)
Pengujian 4	Benar 1 (1)	Pengujian 24	Benar 1 (1)
Pengujian 5	Benar 1 (1)	Pengujian 25	Benar 1 (1)
Pengujian 6	Benar 1 (1)	Pengujian 26	Benar 1 (1)
Pengujian 7	Benar 1 (1)	Pengujian 27	Benar 1 (1)
Pengujian 8	Benar 1 (1)	Pengujian 28	Benar 1 (1)
Pengujian 9	Benar 1 (1)	Pengujian 29	Benar 1 (1)
Pengujian 10	Benar 1 (1)	Pengujian 30	Benar 1 (1)
Pengujian 11	Benar 1 (1)	Pengujian 31	Benar 1 (1)
Pengujian 12	Benar 1 (1)	Pengujian 32	Benar 1 (1)
Pengujian 13	Benar 1 (1)	Pengujian 33	Benar 1 (1)
Pengujian 14	Benar 1 (1)	Pengujian 34	Benar 1 (1)
Pengujian 15	Benar 1 (1)	Pengujian 35	Benar 1 (1)
Pengujian 16	Benar 1 (1)	Pengujian 36	Benar 1 (1)
Pengujian 17	Benar 1 (1)	Pengujian 37	Benar 1 (1)
Pengujian 18	Benar 1 (1)	Pengujian 38	Benar 1 (1)
Pengujian 19	Benar 1 (1)	Pengujian 39	Benar 1 (1)
Pengujian 20	Benar 1 (1)	Pengujian 40	Benar 1 (1)
Total		Benar	40
		Salah	0

Tabel 4. 12 Pengujian Dataset *Bruguiera gymnorhiza*

Pengujian Ke-	Hasil Deteksi (Jumlah Objek)	Pengujian Ke-	Hasil Deteksi (Jumlah Objek)
Pengujian 1	Benar 1 (1)	Pengujian 21	Benar 1 (1)
Pengujian 2	Benar 1 (1)	Pengujian 22	Salah 1 (1)
Pengujian 3	Salah 1 (1)	Pengujian 23	Benar 1 (1)
Pengujian 4	Salah 1 (1)	Pengujian 24	Benar 1 (1)
Pengujian 5	Benar 1 (1)	Pengujian 25	Benar 1 (1)
Pengujian 6	Benar 1 (1)	Pengujian 26	Benar 1 (1)
Pengujian 7	Benar 1 (1)	Pengujian 27	Benar 1 (1)
Pengujian 8	Salah 1 (1)	Pengujian 28	Benar 1 (1)
Pengujian 9	Benar 1 (1)	Pengujian 29	Salah 1 (1)
Pengujian 10	Benar 1 (1)	Pengujian 30	Benar 2 (2)
Pengujian 11	Salah 1 (1)	Pengujian 31	Benar 1 (1)
Pengujian 12	Benar 1 (1)	Pengujian 32	Benar 1 (1)
Pengujian 13	Salah 1 (1)	Pengujian 33	Salah 1 (1)
Pengujian 14	Benar 1 (1)	Pengujian 34	Benar 1 (1)
Pengujian 15	Benar 1 (1)	Pengujian 35	Benar 1 (1)
Pengujian 16	Salah 1 (1)	Pengujian 36	Benar 1 (1)
Pengujian 17	Benar 1 (1)	Pengujian 37	Benar 1 (1)
Pengujian 18	Benar 1 (1)	Pengujian 38	Benar 1 (1)
Pengujian 19	Benar 1 (1)	Pengujian 39	Salah 1 (1)
Pengujian 20	Benar 1 (1)	Pengujian 40	Benar 1 (1)
Total		Benar	31
		Salah	10

Tabel 4. 13 Pengujian Dataset *Rhizophora apiculata*

Pengujian Ke-	Hasil Deteksi (Jumlah Objek)	Pengujian Ke-	Hasil Deteksi (Jumlah Objek)
Pengujian 1	Salah 1 (1)	Pengujian 21	Salah 1 (1)
Pengujian 2	Benar 1 (1)	Pengujian 22	Benar 1 (1)
Pengujian 3	Benar 1 (1)	Pengujian 23	Salah 1 (1)
Pengujian 4	Salah 1 (1)	Pengujian 24	Salah 1 (1)
Pengujian 5	Salah 1 (1)	Pengujian 25	Salah 1 (1)
Pengujian 6	Salah 1 (1)	Pengujian 26	Salah 1 (1)
Pengujian 7	Benar 1 (1)	Pengujian 27	Salah 1 (1)
Pengujian 8	Salah 1 (1)	Pengujian 28	Benar 1 (1)
Pengujian 9	Benar 1 Salah 1 (2)	Pengujian 29	Benar 1 (1)
Pengujian 10	Benar 1 (1)	Pengujian 30	Benar 1 (1)
Pengujian 11	Salah 1 (1)	Pengujian 31	Salah 1 (1)
Pengujian 12	Benar 1 (1)	Pengujian 32	Benar 1 (1)
Pengujian 13	Salah 1 (1)	Pengujian 33	Benar 1 (1)
Pengujian 14	Benar 1 (1)	Pengujian 34	Benar 1 (1)
Pengujian 15	Benar 1 (1)	Pengujian 35	Benar 1 (1)
Pengujian 16	Salah 1 (1)	Pengujian 36	Benar 1 Salah 1 (2)
Pengujian 17	Benar 1 (1)	Pengujian 37	Salah 1 (1)
Pengujian 18	Salah 2 (2)	Pengujian 38	Benar 1 (1)
Pengujian 19	Benar 1 (1)	Pengujian 39	Salah 1 (1)
Pengujian 20	Benar 1 (1)	Pengujian 40	Benar 1 (1)
Total		Benar	22
		Salah	21

Tabel 4. 14 Pengujian Dataset *Scyphiphora hydropyllacea*

Pengujian Ke-	Hasil Deteksi (Jumlah Objek)	Pengujian Ke-	Hasil Deteksi (Jumlah Objek)
Pengujian 1	Benar 1 (1)	Pengujian 21	Benar 1 (1)
Pengujian 2	Benar 1 (1)	Pengujian 22	Benar 1 (1)
Pengujian 3	Benar 1 (1)	Pengujian 23	Benar 1 (1)
Pengujian 4	Benar 1 (1)	Pengujian 24	Benar 1 (1)
Pengujian 5	Benar 1 (1)	Pengujian 25	Benar 1 (1)
Pengujian 6	Benar 1 (1)	Pengujian 26	Benar 1 (1)
Pengujian 7	Benar 1 (1)	Pengujian 27	Benar 1 (1)
Pengujian 8	Benar 1 (1)	Pengujian 28	Benar 1 (1)
Pengujian 9	Benar 2 (2)	Pengujian 29	Benar 1 (1)
Pengujian 10	Benar 1 (1)	Pengujian 30	Benar 1 (1)
Pengujian 11	Benar 1 (1)	Pengujian 31	Benar 1 (1)
Pengujian 12	Benar 2 (2)	Pengujian 32	Benar 1 (1)
Pengujian 13	Benar 1 (1)	Pengujian 33	Salah 1 (1)
Pengujian 14	Benar 1 (1)	Pengujian 34	Benar 1 (1)
Pengujian 15	Benar 1 (1)	Pengujian 35	Benar 1 Salah 1 (2)
Pengujian 16	Benar 1 (1)	Pengujian 36	Salah 1 (1)
Pengujian 17	Benar 1 (1)	Pengujian 37	Salah 1 (1)
Pengujian 18	Benar 1 (1)	Pengujian 38	Benar 1 (1)
Pengujian 19	Benar 1 (1)	Pengujian 39	Salah 1 (1)
Pengujian 20	Benar 1 (1)	Pengujian 40	Benar 1 (1)
Total		Benar	38
		Salah	5

Tabel 4. 15 Pengujian Dataset *Rhizophora mucronata*

Pengujian Ke-	Hasil Deteksi (Jumlah Objek)	Pengujian Ke-	Hasil Deteksi (Jumlah Objek)
Pengujian 1	Benar 1 (1)	Pengujian 21	Benar 1 (1)
Pengujian 2	Benar 1 (1)	Pengujian 22	Benar 1 (1)
Pengujian 3	Salah 1 (1)	Pengujian 23	Benar 1 (1)
Pengujian 4	Benar 1 (1)	Pengujian 24	Benar 1 (1)
Pengujian 5	Benar 1 (1)	Pengujian 25	Benar 1 (1)
Pengujian 6	Salah 1 (1)	Pengujian 26	Benar 1 (1)
Pengujian 7	Benar 1 (1)	Pengujian 27	Benar 1 (1)
Pengujian 8	Benar 1 (1)	Pengujian 28	Salah 1 (1)
Pengujian 9	Benar 1 (1)	Pengujian 29	Benar 1 (1)
Pengujian 10	Benar 2 (2)	Pengujian 30	Benar 1 (1)
Pengujian 11	Benar 2 (2)	Pengujian 31	Benar 1 (1)
Pengujian 12	Benar 1 (1)	Pengujian 32	Benar 1 (1)
Pengujian 13	Benar 1 (1)	Pengujian 33	Benar 1 Salah 1 (2)
Pengujian 14	Benar 2 (2)	Pengujian 34	Salah 1 (1)
Pengujian 15	Benar 2 (2)	Pengujian 35	Salah 1 (1)
Pengujian 16	Benar 2 (2)	Pengujian 36	Benar 1 (1)
Pengujian 17	Benar 2 (2)	Pengujian 37	Benar 1 (1)
Pengujian 18	Benar 1 (1)	Pengujian 38	Benar 1 (1)
Pengujian 19	Benar 1 (1)	Pengujian 39	Benar 1 (1)
Pengujian 20	Benar 1 (1)	Pengujian 40	Salah 1 (1)
Total		Benar	40
		Salah	7

Tabel 4. 16 Pengujian Dataset *Brugueira cylindrica*

Pengujian Ke-	Hasil Deteksi (Jumlah Objek)	Pengujian Ke-	Hasil Deteksi (Jumlah Objek)
Pengujian 1	Benar 1 (1)	Pengujian 21	Benar 2 Salah 1 (3)
Pengujian 2	Salah 1 (1)	Pengujian 22	Benar 1 (1)
Pengujian 3	Benar 1 (1)	Pengujian 23	Benar 1 (1)
Pengujian 4	Benar 1 (1)	Pengujian 24	Benar 1 (1)
Pengujian 5	Benar 1 (1)	Pengujian 25	Benar 1 (1)
Pengujian 6	Benar 1 (1)	Pengujian 26	Benar 1 (1)
Pengujian 7	Benar 1 (1)	Pengujian 27	Benar 1 (1)
Pengujian 8	Benar 1 (1)	Pengujian 28	Benar 1 (1)
Pengujian 9	Benar 1 (1)	Pengujian 29	Benar 1 (1)
Pengujian 10	Benar 2 (2)	Pengujian 30	Benar 1 (1)
Pengujian 11	Benar 1 (1)	Pengujian 31	Benar 1 Salah 1 (2)
Pengujian 12	Benar 1 (1)	Pengujian 32	Benar 1 (1)
Pengujian 13	Benar 1 (1)	Pengujian 33	Benar 1 (1)
Pengujian 14	Benar 1 (1)	Pengujian 34	Benar 1 (1)
Pengujian 15	Benar 1 (1)	Pengujian 35	Benar 1 (1)
Pengujian 16	Salah 1 (1)	Pengujian 36	Benar 1 (1)
Pengujian 17	Benar 1 (1)	Pengujian 37	Benar 1 (1)
Pengujian 18	Benar 2 (2)	Pengujian 38	Benar 1 (1)
Pengujian 19	Benar 1 (1)	Pengujian 39	Benar 1 (1)
Pengujian 20	Benar 1 (1)	Pengujian 40	Benar 1 (1)
Total		Benar	41
		Salah	4


Tabel 4. 17 Pengujian Dataset *Xylocarpus granatum*

Pengujian Ke-	Hasil Deteksi (Jumlah Objek)	Pengujian Ke-	Hasil Deteksi (Jumlah Objek)
Pengujian 1	Benar 1 (1)	Pengujian 21	Benar 1 (1)
Pengujian 2	Benar 1 (1)	Pengujian 22	Benar 1 (1)
Pengujian 3	Benar 2 (2)	Pengujian 23	Benar 2 (2)
Pengujian 4	Benar 1 (1)	Pengujian 24	Benar 1 (1)
Pengujian 5	Benar 1 (1)	Pengujian 25	Benar 1 (1)
Pengujian 6	Salah 1 (1)	Pengujian 26	Benar 1 (1)
Pengujian 7	Benar 2 (2)	Pengujian 27	Benar 2 (2)
Pengujian 8	Benar 1 (1)	Pengujian 28	Benar 2 (2)
Pengujian 9	Benar 1 (1)	Pengujian 29	Benar 1 (1)
Pengujian 10	Benar 1 (1)	Pengujian 30	Benar 2 (2)
Pengujian 11	Benar 2 (2)	Pengujian 31	Benar 1 (1)
Pengujian 12	Benar 1 (1)	Pengujian 32	Benar 1 (1)
Pengujian 13	Benar 1 (1)	Pengujian 33	Benar 1 (1)
Pengujian 14	Benar 1 (1)	Pengujian 34	Benar 1 (1)
Pengujian 15	Benar 1 (1)	Pengujian 35	Benar 1 (1)
Pengujian 16	Salah 1 (1)	Pengujian 36	Benar 1 (1)
Pengujian 17	Benar 1 (1)	Pengujian 37	Benar 1 (1)
Pengujian 18	Benar 1 (1)	Pengujian 38	Benar 1 (1)
Pengujian 19	Benar 1 (1)	Pengujian 39	Benar 1 (1)
Pengujian 20	Benar 1 (1)	Pengujian 40	Benar 1 (1)
Total		Benar	45
		Salah	2

Berdasarkan hasil pengujian pada tabel 4.6 hingga 4.14 dari 40 objek pada setiap kelas, kelas yang memiliki prediksi yang benar yang banyak pada saat pengujian adalah kelas *Avicennia Lanata* sebesar 42 prediksi benar dengan kesalahan sebanyak sebesar 4, kelas *Brugueira cylindrica* sebesar 41 prediksi benar dengan kesalahan sebanyak sebesar 4, kelas *Lumnitzera liitorea* sebesar 47 prediksi benar dengan kesalahan sebesar 0, kelas *Rhizophora mucronata* sebesar 40 prediksi benar dengan kesalahan sebesar 7, kelas *Scyphiphora hydrophyllacea* sebesar 40 prediksi benar dengan kesalahan sebesar 5, kelas *Sonneratia Alba* sebesar 40 prediksi benar dengan kesalahan sebesar 0 serta *Xylocarpus granatum* sebesar 45 prediksi benar dengan kesalahan sebesar 2. Namun disisi lain kelas dengan prediksi benar terendah di memiliki oleh kelas *Bruguiera gymnorhiza* dengan prediksi benar sebesar 31 dan kesalahan sebesar 10 serta kelas *Rhizophora apiculata* dengan prediksi benar sebesar 22 dan kesalahan sebesar 21. Hal ini bisa terjadi karena kedua kelas yaitu *Bruguiera gymnorhiza* dan *Rhizophora apiculata* memiliki banyak kesamaan yang mirip dalam segi bentuk, struktur, warna dengan daun lain seperti kelas *Brugueira cylindrica*, *Rhizophora mucronata*, namun dalam pengujian menggunakan bagian bunga dari kelas *Bruguiera gymnorhiza* dan *Rhizophora apiculata* prediksi benar sangat menyakinkan dibandingkan prediksi menggunakan bagian daun. Hasil dari metrik evaluasi *Average Precision* (AP) tidak merepresentasikan bahwa prediksi akan selalu berjalan sesuai dengan apa yang telah di peroleh dari hasil evaluasi *Average Precision* (AP), namun hasil sebenarnya adalah evaluasi *Mean Average Precision* (MAP) yang merupakan representasi dari dunia nyata ketika di uji langsung dilapangan dengan evaluasi ketat menggunakan *threshold* 0.5:0.95 yang merupakan evaluasi yang lebih baik dibandingkan dengan menggunakan *Average Precision* (AP) dengan *threshold* hanya 0.5. *Average Precision* (AP) digunakan untuk melihat performa pada setiap kelas pada saat model di *training*, sedangkan *Mean Average Precision* (MAP) digunakan untuk melihat performa keseluruhan kelas pada rentang *threshold* 0.5 hingga 0.95 pada saat model di *training*.

Tabel 4. 18 Hasil Keseluruhan Pengujian *One Label*

Kelas	Total Benar	Total Salah
<i>Avicennia Lanata</i>	40	4
<i>Bruguiera cylindrica</i>	41	4
<i>Bruguiera gymnorhiza</i>	31	10
<i>Lumnitzera liitorea</i>	47	0
<i>Rhizophora apiculata</i>	22	21
<i>Rhizophora mucronata</i>	40	7
<i>Scyphiphora hydrophyllacea</i>	38	5
<i>Sonneratia Alba</i>	40	0
<i>Xylocarpus granatum</i>	45	2



4.3.2 Pengujian Akurasi Pada Dataset *Multi Label*

Berdasarkan hasil dari pengujian *multi label* pada gambar 4.10 (a) hingga (c), model mampu mendeteksi beberapa objek dengan benar, namun terdapat sejumlah objek yang tidak terdeteksi. Hasil ini memberikan gambaran bahwa performa model dalam menghadapi tantang deteksi objek pada kondisi atau lingkungan yang kompleks. Peneliti berpendapat untuk hasil deteksi yang benar menunjukkan bahwa model dapat mengenali fitur visual dari berbagai kelas objek, seperti warna dan bentuk tertentu yang sudah dipelajari selama proses pelatihan. Namun ada beberapa faktor yang menyebabkan model tidak dapat mendeteksi dengan benar seperti fokus objek dalam satu *frame* foto, dimana semakin banyak objek didalam 1 *frame* foto maka fokus dari suatu kelas akan berkurang dibandingkan jika dalam 1 *frame* foto hanya terdiri dari 1 atau 2 objek saja, maka kualitas foto dan fokus pada objek akan lebih baik, hal ini akan menggaburkan fitur visual objek sehingga model sulit mengenali. Faktor lainnya yaitu jarak dalam pengambilan foto dapat dilihat pada gambar 4.10 (c), dimana foto yang diambil terlalu jauh sehingga warna dan bentuk dari suatu kelas tidak terlihat jelas sehingga sulit dikenali oleh model. Faktor inilah yang mengindikasikan bahwa model memerlukan lebih banyak data yang bervariasi pada kondisi objek dalam situasi nyata. Terdapat tantangan lain yaitu ada beberapa kelas yang memiliki karakteristik visual yang hampir sama dengan kelas lain sehingga dapat menyebabkan kesalahan deteksi objek pada suatu kelas.




Gambar 4. 10 Pengujian Dataset *Multi Label*

4.3.3 Pengujian Akurasi Pada Dataset Pengaruh Posisi Objek

Berdasarkan hasil pengujian dari posisi objek pada gambar 4.11 menunjukkan bahwa posisi objek memiliki pengaruh yang cukup signifikan dalam mendeteksi objek bagi semua kelas khususnya pada kelas *Avicennia Lanata*. Dapat dilihat pada gambar (a) dan (b), model mendeteksi dengan tepat bahwa objek tersebut adalah *Avicennia Lanata*, hal ini menunjukkan bahwa objek terlihat jelas yang dapat mempermudah model dapat mengenalinya. Sebaliknya, pada gambar (c) dan (d), model mendeteksi kelas *Lumnitzera liitorea* dan *Xylocarpus granatum*, hal ini peneliti berpendapat disebabkan karena pada gambar (c) daun ditutupi oleh bunga dari kelas *Avicennia Lanata* dan posisi daun terlihat lebih kecil dan daun tidak terlihat jelas dan untuk gambar (d) daun terlihat jelas namun posisi daun menyerupai posisi yang mirip seperti pada data *training* kelas *Xylocarpus granatum* pada saat proses pelatihan model dan daun *Avicennia Lanata* pada gambar (d) memiliki kemiripan dari fitur visual seperti warna dan bentuk pada kelas *Xylocarpus granatum*.





Gambar 4. 11 Pengaruh Posisi Objek

4.3.4 Pengujian Akurasi Pada Bukan Jenis Mangrove

Tabel 4. 19 Pengujian Dataset Bukan Jenis Mangrove Gambar Random

Pengujian Ke	Hasil Deteksi	Pengujian Ke	Hasil Deteksi
Pengujian 1	Benar	Pengujian 11	Salah
Pengujian 2	Benar	Pengujian 12	Benar
Pengujian 3	Benar	Pengujian 13	Benar
Pengujian 4	Benar	Pengujian 14	Benar
Pengujian 5	Benar	Pengujian 15	Salah
Pengujian 6	Benar	Pengujian 16	Benar
Pengujian 7	Salah	Pengujian 17	Benar
Pengujian 8	Benar	Pengujian 18	Benar
Pengujian 9	Benar	Pengujian 19	Benar
Pengujian 10	Benar	Pengujian 20	Benar
Total		Benar	17
		Salah	3

Tabel 4. 20 Pengujian Dataset Bukan Jenis Mangrove Objek Dominan Hijau

Pengujian Ke	Hasil Deteksi	Pengujian Ke	Hasil Deteksi
Pengujian 1	Benar	Pengujian 11	Benar
Pengujian 2	Benar	Pengujian 12	Benar
Pengujian 3	Salah	Pengujian 13	Salah
Pengujian 4	Salah	Pengujian 14	Salah
Pengujian 5	Salah	Pengujian 15	Salah
Pengujian 6	Salah	Pengujian 16	Benar
Pengujian 7	Salah	Pengujian 17	Salah
Pengujian 8	Salah	Pengujian 18	Benar
Pengujian 9	Salah	Pengujian 19	Benar
Pengujian 10	Salah	Pengujian 20	Salah
Total		Benar	7
		Salah	13

Berdasarkan hasil pengujian ini, terdapat 40 gambar yang terbagi menjadi 2 yaitu gambar dengan objek *Random* dan gambar dengan objek yang dominan warna hijau. Pada gambar dengan objek *Random* seperti pohon, rumah, motor, plang lalu lintas, kucing, sampah, tong sampah, kayu, seng, kursi, bekicot, sepatu, *rice cooker*, ayam, laptop, botol minuman, lemari, kipas. Sedangkan pada gambar dengan objek yang dominan warna hijau seperti ilalang, daun pohon ketapang, plang jalan, daun ubi, daun pisang, daun mangga, daun salam, daun kelengkeng, karung, lidah buaya, tong sampah, daun jambu, sabun muka, tabung gas, jaket, teko, *tupperware*, tudung saji. Dapat dilihat pada gambar 4.12 terdapat kesalahan deteksi yang terjadi karena bentuk atau warna visual objek menyerupai

pada salah satu kelas dari mangrove seperti pada gambar (a) yang merupakan tong sampah, tong sampah yang bentuk silinder ini yang menyerupai kelas *Avicennia Lanata* sehingga sistem salah dalam mengidentifikasi bahwasanya ini bukan mangrove dan gambar (b) yang merupakan daun dari pohon salam yang mirip seperti kelas *Xylocarpus granatum*.



Gambar 4. 12 Pengujian Dataset Bukan Mangrove

4.4 Hasil Perancangan Aplikasi Mobile

4.4.1 Tampilan Halaman *Splash Screen*



Gambar 4. 13 Tampilan *Splash Screen*

Gambar 4.13 menunjukkan tampilan halaman *Splash Screen* yang dimuat beberapa detik ketika pengguna membuka aplikasi yang terdapat logo aplikasi.


4.4.2 Tampilan Halaman *Home*



Gambar 4. 14 Tampilan Halaman *Home*

Gambar 4.14 menunjukkan tampilan halaman *Home*, dimana terdapat tampilan nama aplikasi serta logo universitas, pengguna diberikan menu ambil foto, unggah gambar, jenis mangrove dan *developer*.


4.4.3 Tampilan Ambil Foto



Gambar 4. 15 Tampilan Halaman Ambil Foto

Gambar 4.15 menunjukkan tampilan halaman ambil foto, dimana pengguna akan diminta akses izin kamera untuk memulai mengambil foto yang ingin di deteksi, jenis file yang didukung pada pengambilan foto adalah dengan format .jpeg dan jpg.


4.4.4 Tampilan Unggah Gambar



Gambar 4. 16 Tampilan Halaman Unggah Gambar

Gambar 4.16 menunjukkan tampilan halaman unggah gambar, dimana pengguna akan mengambil gambar di penyimpanan perangkat pengguna yang ingin di deteksi, jenis file yang didukung pada pengambilan gambar adalah dengan format .jpeg dan jpg.

4.4.5 Tampilan Petunjuk



Gambar 4. 17 Tampilan Halaman Aturan

Gambar 4.17 menunjukkan tampilan halaman aturan, dalam pengambilan foto dan unggah gambar, ada beberapa aturan yang dibuat agar hasil deteksinya benar dan baik, jika pengguna telah membaca aturan tersebut, pilih tombol mengerti dan akan melanjut ke tahap selanjutnya.

4.4.6 Tampilan Validasi Foto



Gambar 4. 18 Tampilan Halaman Validasi Gambar

Gambar 4.18 menunjukkan tampilan halaman validasi gambar, hal ini berguna agar jika pengguna kurang cocok atau kurang jelas objek yang di foto pengguna dapat mengambil ulang, kemudian pilih menu prediksi, maka foto akan di proses untuk dideteksi.


4.4.7 Tampilan Hasil Deteksi



Gambar 4. 19 Tampilan Halaman Hasil Deteksi

Gambar 4.19 menunjukkan tampilan halaman hasil deteksi, dimana pengguna dapat melihat informasi dari objek seperti foto yang telah di *bounding box* beserta jenis mangrove dan tingkat keyakinannya serta catatan dari jenis mangrove, deskripsi, ekologi, manfaat, penyebaran dan gambar bunga dari jenis mangrove yang dideteksi.

4.4.8 Tampilan Jenis Mangrove



Gambar 4. 20 Tampilan Halaman Jenis Mangrove

Gambar 4.20 menunjukkan tampilan halaman jenis-jenis mangrove yang berisikan gambar, nama dan deskripsi singkat terkait jenis mangrove


4.4.9 Tampilan Detail Jenis Mangrove



Gambar 4. 21 Tampilan Halaman Detail Jenis Mangrove

Gambar 4.21 menunjukkan tampilan halaman detail dari jenis mangrove yang ingin dilihat, terdapat informasi seperti jenis mangrove, deskripsi, ekologi, manfaat, penyebaran dan gambar bunga.

4.4.10 Tampilan *Developer*



Gambar 4. 22 Tampilan Halaman *Developer*

Gambar 4.22 menampilkan halaman *developer* atau pengembang aplikasi yang merupakan profile singkat pembuatan aplikasi Mangrove .

BAB V

PENUTUP

5.1 Kesimpulan

Kesimpulan yang dapat di peroleh dari penelitian tentang identifikasi jenis mangrove menggunakan *pre-trained* model *Faster R-CNN ResNet-50 FPN* adalah pengaruh *batch size* terhadap performa model dari hasil dari pelatihan didapatkan bahwa mAP terbaik dari keseluruhan kelas pada *batch size* 4 dan *epoch* 30 dengan nilai mAP sebesar 62,59% serta AP perkelas yaitu *Avicennia Lanata* sebesar 95,61%, *Bruguiera cylindrica* sebesar 82,27%, *Bruguiera gymnorhiza* 97,72%, *Lumnitzera liitorea* 96,46%, *Rhizophora apiculata* 95,42%, *Rhizophora mucronata* 93,19%, *Scyphiphora hydrophyllacea* 97,87%, *Sonneratia Alba* 99,00%, *Xylocarpus granatum* 89,99% menunjukkan akurasi dan generalisasi yang baik dibandingkan *batch size* lainnya. Secara keseluruhan, model *Faster R-CNN* dengan *batch size* 4 terbukti dapat memberikan performa terbaik dalam mengidentifikasi jenis mangrove pada bagian daun dan bunga mangrove. Dengan tantangan kejelasan dan fokus gambar pada objek, jarak dari objek, posisi objek serta objek yang bukan mangrove namun memiliki dominasi warna hijau serta kemiripan fitur antar kelas yang menentukan keberhasilan deteksi.

5.2 Saran

Berdasarkan hasil penelitian yang telah dilakukan, peneliti menyarankan untuk menambah variasi dan keberagaman dataset serta menambahkan kelas bukan mangrove dan mengidentifikasi morfologi selain dari bagian bunga dan daun pada mangrove seperti akar, batang dan buah dan menambahkan teknik pengambilan dataset pada bagian belakang pada daun serta melakukan percobaan dengan menghapus *background* dari foto untuk dalam melakukan proses *training* model. Hal ini bertujuan agar model dapat melakukan deteksi lebih baik dan akurat serta mengurangi kecenderungan model untuk mengklasifikasi objek bukan mangrove sebagai jenis mangrove. Selain itu, penelitian selanjutnya dapat mengeksplorasi berbagai parameter seperti *batch size*, menambah *epoch* selama pelatihan dengan

melihat berbagai faktor seperti mengubah parameter *learning rate*, *weight decay*, *momentum*, *optimizer*, *gamma* dan *step size* guna meningkatkan stabilitas dan mendapatkan hasil metrik evaluasi mAP yang lebih baik dari sebelumnya. Dalam penelitian selanjutnya, peneliti menyarankan untuk melakukan eksperimen dengan mengubah arsitektur CNN sebagai *backbone* seperti MobileNet, AlexNet, EfiicientNet dan arsitektur lainnya yang diharapkan dapat memberikan perbandingan performa serta membantu meningkatkan akurasi deteksi objek dari berbagai kondisi.



DAFTAR PUSTAKA

- Abas, S. (2022). Diagnosing the Leukemia using Faster Region based Convolutional Neural Network. *Journal of Applied Science and Technology Trends*, 3(02), 89–92. <https://doi.org/10.38094/jastt302134>
- Ahmed, K. M., Ghareh, M. F., Matus, M., Shenavarmasouleh, F., Manella, P. L., Ioannis, Z., & Amini, M. H. (2023). Towards Real-time House Detection in Aerial Imagery Using Faster Region-based Convolutional Neural Network. *IPSI Transactions on Internet Research*, 19(02).
- Andriushchenko, M., D'Angelo, F., Varre, A., & Flammarion, N. (2024). *Why Do We Need Weight Decay in Modern Deep Learning?* <https://arxiv.org/abs/2310.04415>
- Angel, J. S., Andrushia, A. D., Neebha, T. M., Accouche, O., Saker, L., & Anand, N. (2024). Faster Region Convolutional Neural Network (FRCNN) Based Facial Emotion Recognition. *Computers, Materials and Continua*, 79(2), 2427–2448. <https://doi.org/10.32604/cmc.2024.047326>
- Apdillah, D., Wahyudin, Razai, T. S., Chalet, C., Suryanti, A., Zulkarnaen, Y., & Azizah, D. (2023). Carrying capacity of mangrove environment for development of river cruise ecotourism in Pengudang, Bintan Island, Indonesia. *IOP Conference Series: Earth and Environmental Science*, 1148(1). <https://doi.org/10.1088/1755-1315/1148/1/012018>
- Asnur, P., Kosasih, R., Madenda, S., & Rahayu, D. A. (2023). Identification of mangrove tree species using deep learning method. *International Journal of Advances in Applied Sciences*, 12(2), 163–170. <https://doi.org/10.11591/ijaas.v12.i2.pp163-170>
- Azmi, K., Defit, S., & Putra Indonesia YPTK Padang Jl Raya Lubuk Begalung-Padang-Sumatera Barat, U. (2023). *Implementasi Convolutional Neural*

Network (CNN) Untuk Klasifikasi Batik Tanah Liat Sumatera Barat. 16(1), 2023.

- Charli, F., Syaputra, H., Akbar³, M., Sauda, S., & Panjaitan, F. (2020). Implementasi Metode Faster Region Convolutional Neural Network (Faster R-CNN) Untuk Pengenalan Jenis Burung Lovebird. In *Journal of Information Technology Ampera* (Vol. 1, Issue 3). <https://journal-computing.org/index.php/journal-ita/index>
- Chen, C., Wang, S., & Huang, S. (2023). An improved faster RCNN-based weld ultrasonic atlas defect detection method. *Measurement and Control (United Kingdom)*, 56(3–4), 832–843. <https://doi.org/10.1177/00202940221092030>
- Darmayanti, E. D., & Anggraini, R. (2024). Kondisi Ekosistem Mangrove Pesisir Kawal Kabupaten Bintan Kepulauan Riau. *Jurnal Laot Ilmu Kelautan*, 6(1), 16. <https://doi.org/10.35308/jlik.v6i1.9174>
- Edo, E., Susiana, S., Suhana, M. P., & Rochmady, R. (2021). Condition of mangrove in the waters of Pangkil Village, Teluk Bintan District, Bintan Regency. *Akuatikisle: Jurnal Akuakultur, Pesisir Dan Pulau-Pulau Kecil*, 6(1), 1–8. <https://doi.org/10.29239/j.akuatikisle.6.1.1-8>
- Faiz Nashrullah, Suryo Adhi Wibowo, & Gelar Budiman. (2020). The Investigation of Epoch Parameters in ResNet-50 Architecture for Pornographic Classification. *Journal of Computer, Electronic, and Telecommunication*, 1(1). <https://doi.org/10.52435/complete.v1i1.51>
- Gijandren, A. (2020). *Edge detection using hybrid dynamic binary threshold*. IEEE.
- Hou, J., Che, Y., Fang, Y., Bai, H., & Sun, L. (2024). Early Bruise Detection in Apple Based on an Improved Faster RCNN Model. *Horticulturae*, 10(1). <https://doi.org/10.3390/horticulturae10010100>
- Hu, B., & Wang, J. (2020). Detection of PCB Surface Defects with Improved Faster-RCNN and Feature Pyramid Network. *IEEE Access*, 8, 108335–108345. <https://doi.org/10.1109/ACCESS.2020.3001349>

- Ibitoye, O. T. (2024). Fake Currency Detection using Modified Faster Region-Based Convolutional Neural Network. *International Journal of Electrical Engineering and Computer Science*, 6, 46–50. <https://doi.org/10.37394/232027.2024.6.5>
- Ifayatin, H. N., Sarita, I., & Saputra, R. A. (2024). *Sistem Deteksi Penyakit Pneumonia Menggunakan Algoritma Faster R-CNN Berbasis Citra Digital Rontgen Dada*. 12(4). <https://doi.org/10.26418/justin.v12i4.81304>
- Immanuel Sinabang, Klarita Dwijayanti Waruwu, Geby Pauliana, Winda Rahayu, & Meilinda Suriani Harefa. (2022). Analisis Pemanfaatan Keanekaragaman Mangrove oleh Masyarakat di Pesisir Pantai Mangrove Paluh Getah. *J-CoSE: Journal of Community Service & Empowerment*, 1(1), 10–21. <https://doi.org/10.58536/j-cose.v1i1.7>
- Ji, S., Li, W., Zhang, B., Zhou, L., & Duan, C. (2021). Bucket Teeth Detection Based on Faster Region Convolutional Neural Network. *IEEE Access*, 9, 17649–17661. <https://doi.org/10.1109/ACCESS.2021.3054436>
- Jiemesha, M., & Wonohadidjojo, D. M. (2025). *Classification of Skin Diseases Using Transfer Learning with ResNet-50 Architecture and Data Preprocessing Using Real-ESRGAN and Wiener Filter*. 07, 2025. <https://doi.org/10.52985/insyst.v7i1.399>
- Junaidi, S., Devegi, M., & Kurniawan, H. (2023). Pelatihan Pengolahan dan Visualisasi Data Penduduk menggunakan Python. *ADMA : Jurnal Pengabdian Dan Pemberdayaan Masyarakat*, 4(1), 151–162. <https://doi.org/10.30812/adma.v4i1.2963>
- Kementerian Lingkungan Hidup dan Kehutanan. (2021). *Peta Mangrove Nasional (PMN) pada tahun 2021*.
- Li, W. (2021). Analysis of Object Detection Performance Based on Faster R-CNN. *Journal of Physics: Conference Series*, 1827(1). <https://doi.org/10.1088/1742-6596/1827/1/012085>

- Liubana, D. V., Ratu, A., Sabu, R. M., Gateria, A., Costa, D., & Pereira, A. (2022). Identifikasi Jenis-Jenis Mangrove Di Kawasan Ekowisata Mangrove Di Desa Dualaus Kecamatan Kakuluk Mesak Kabupaten Belu. In *Jurnal Aquatik, Oktober* (Vol. 5, Issue 2). <http://ejurnal.undana.ac.id/jaqu/index>
- Maryam, S., Daningsih, E., & Mardiyyaningsih, A. N. (2024). Identifikasi Tumbuhan Mangrove di Hutan Lindung Padu Empat-Lebak Kerawang Desa Batu Ampar Kabupaten Kubu Raya. *Bioscientist : Jurnal Ilmiah Biologi*, 12(1), 1382. <https://doi.org/10.33394/bioscientist.v12i1.11285>
- Montesinos López, O. A., Montesinos López, A., & Crossa, J. (2022). Convolutional Neural Networks. In *Multivariate Statistical Machine Learning Methods for Genomic Prediction* (pp. 533–577). Springer International Publishing. https://doi.org/10.1007/978-3-030-89010-0_13
- Naushad, R., Kaur, T., & Ghaderpour, E. (2021). Deep transfer learning for land use and land cover classification: A comparative study. *Sensors*, 21(23). <https://doi.org/10.3390/s21238083>
- Nggara Imanuel, A., & Nasution, S. (2020). Condition Of Mangrove Forests In Dompak Urban Village Bukit Bestari Sub-District Riau Island Province. In *Asian Journal of Aquatic Sciences, Desember 2020* (Vol. 3, Issue 3).
- Nugroho, A., Arie Widhining, D. K., Alif Fiolana, F., Studi Teknik Elektro, P., & Islam Kadiri, U. (2023). *Klasifikasi Helm Keselamatan Menggunakan Metode Convolutional Neural Network (CNN)*.
- Padilla, R., Netto, S. L., Da Silva, E. A. B., & Netto, S. L. (2020). *A Survey on Performance Metrics for Object-Detection Algorithms*. <https://doi.org/10.1109/IWSSIP48289.2020>
- Padilla, R., Passos, W. L., Dias, T. L. B., Netto, S. L., & Da Silva, E. A. B. (2021). A comparative analysis of object detection metrics with a companion open-source toolkit. *Electronics (Switzerland)*, 10(3), 1–28. <https://doi.org/10.3390/electronics10030279>

- Pan, X., Huan, Z., Li, Y., & Cao, Y. (2024). Enhancement of GUI Display Error Detection Using Improved Faster R-CNN and Multi-Scale Attention Mechanism. *Applied Sciences (Switzerland)*, 14(3). <https://doi.org/10.3390/app14031144>
- PARDEDE, J., & HARDIANSAH, H. (2022). Deteksi Objek Kereta Api menggunakan Metode Faster R-CNN dengan Arsitektur VGG 16. *MIND Journal*, 7(1), 21–36. <https://doi.org/10.26760/mindjournal.v7i1.21-36>
- Pardede, J., & Rijal, K. (2025). The Effect of Hyperparameters on Faster R-CNN in Face Recognition Systems. *Jurnal RESTI (Rekayasa Sistem Dan Teknologi Informasi)*, 9(3), 436–448. <https://doi.org/10.29207/resti.v9i3.6405>
- Pototan, B. L., Capin, N. C., Delima, A. G. D., & Novero, A. U. (2021). Assessment of mangrove species diversity in banaybanay, davao oriental, philippines. *Biodiversitas*, 22(1), 144–153. <https://doi.org/10.13057/biodiv/d220120>
- Pratama, G. A., Puspaningrum, E. Y., & Maulana, H. (2024). Convolutional Neural Network Dan Faster Region Convolutional Neural Network Untuk Klasifikasi Kualitas Biji Kopi Arabika. *Jurnal Informatika Dan Teknik Elektro Terapan*, 12(3). <https://doi.org/10.23960/jite.v12i3.4887>
- Pujiono, H., Vitianingsih, A. V., Kacung, S., Lidya Maukar, A., & Fitri Ana Wati, S. (2024). Application of Faster R-CNN Deep Learning Method for Rice Plant Disease Detection. *Jurnal ELTIKOM*, 8(2), 111–118. <https://doi.org/10.31961/eltikom.v8i2.1165>
- Rahim, U. F., & Mineno, H. (2020). Tomato Flower Detection and Counting in Greenhouses Using Faster Region-Based Convolutional Neural Network. *Journal of Image and Graphics*, 8(4), 107–113. <https://doi.org/10.18178/joig.8.4.107-113>
- Raiaan, M. A. K., Sakib, S., Fahad, N. M., Mamun, A. Al, Rahman, M. A., Shatabda, S., & Mukta, M. S. H. (2024). A systematic review of hyperparameter optimization techniques in Convolutional Neural Networks.

- In *Decision Analytics Journal* (Vol. 11). Elsevier Inc.
<https://doi.org/10.1016/j.dajour.2024.100470>
- Rignolda, D. (2018). *Mangrove Biologi, Ekologi, Rehabilitasi, dan Konservasi*.
- Rizki, F., Kharisma Putra, M. P., Assuja, M. A., & Ariany, F. (2023). Implementasi Deep Leraning Lenet Dengan Augmentasi Data Pada Identifikasi Anggrek. *Jurnal Informatika Dan Rekayasa Perangkat Lunak*, 4(3), 357–366.
<https://doi.org/10.33365/jatika.v4i3.3652>
- Romadhon, M. S., & Setiyono, B. (2024). Monitoring Pemakaian Masker Berbasis Video Menggunakan Metode Faster R-CNN. *Jurnal Sains Dan Seni ITS*, 12(2), A66–A72.
- Salim, M. R. A., Sthevanie, F. R., & Kurniawan Nur. (2023). *Pendeteksi Masker pada Gambar Menggunakan Model Deep Learning Yolo-v2 dengan ResNet-50*.
- Soeprobowati, T. R., Anggoro, S., Puryono, S., Purnaweni, H., Sularto, R. B., & Meryah, R. (2022). Species Composition and Distribution in the Mangrove Ecosystem in the City of Bengkulu, Indonesia. *Water (Switzerland)*, 14(21).
<https://doi.org/10.3390/w14213516>
- Sun, L., Yuan, Y., Qiao, S., & Qi, R. (2024). Detection of Water Meter Digits Based on Improved Faster R-CNN. *Journal of Computer and Communications*, 12(03), 1–13. <https://doi.org/10.4236/jcc.2024.123001>
- Sutama, V. A., Wibowo, S. A., & Rahmania, R. (2020). Investigasi Pengaruh Step Training pada Metode Single Shot Multibox Detector untuk Marker dalam Teknologi Augmented Reality. *Jurnal Ilmiah FIFO*, 12(1), 1.
<https://doi.org/10.22441/fifo.2020.v12i1.001>
- Taye, M. M. (2023). Theoretical Understanding of Convolutional Neural Network: Concepts, Architectures, Applications, Future Directions. In *Computation* (Vol. 11, Issue 3). MDPI. <https://doi.org/10.3390/computation11030052>

- Tian, J., Jin, Q., Wang, Y., Yang, J., Zhang, S., & Sun, D. (2024). Performance analysis of deep learning-based object detection algorithms on COCO benchmark: a comparative study. *Journal of Engineering and Applied Science*, 71(1). <https://doi.org/10.1186/s44147-024-00411-z>
- Tian, Y., Zhang, Y., & Zhang, H. (2023). Recent Advances in Stochastic Gradient Descent in Deep Learning. In *Mathematics* (Vol. 11, Issue 3). MDPI. <https://doi.org/10.3390/math11030682>
- Trinanda. (2024). *Identifikasi Jenis Mangrove Menggunakan Algoritma Backpropagation Dan Learning Vector Quantization* [Skripsi]. Universitas Maritim Raja Ali Haji.
- Wijaya, A. E., Swastika, W., & Kelana, O. H. (2021). Implementasi Transfer Learning Pada Convolutional Neural Network Untuk Diagnosis Covid-19 Dan Pneumonia Pada Citra X-Ray. In *SAINSBERTEK Jurnal Ilmiah Sains & Teknologi* (Vol. 2).
- Yan, H., Chen, C., Jin, G., Zhang, J., Wang, X., & Zhu, D. (2021). Implementation of a modified faster r-cnn for target detection technology of coastal defense radar. *Remote Sensing*, 13(9). <https://doi.org/10.3390/rs13091703>
- Yixuan, L., Dongbo, W., Jiawei, L., & Hui, W. (2023). Aeroengine Blade Surface Defect Detection System Based on Improved Faster RCNN. *International Journal of Intelligent Systems*, 2023. <https://doi.org/10.1155/2023/1992415>
- Yoga Permana, F., Sri Kusuma Aditya, C., & Rizki Chandranegara, D. (2024). Segmentasi dan Klasifikasi Gambar Citra pada Kanker Kulit Menggunakan Metode Convolutional Neural Network (CNN) dengan Arsitektur ResNet-50. *REPOSITOR*, 6(4), 391–404.
- Zaidi, S. S. A., Ansari, M. S., Aslam, A., Kanwal, N., Asghar, M., & Lee, B. (2021). *A Survey of Modern Deep Learning based Object Detection Models*. <http://arxiv.org/abs/2104.11892>

- Zhao, X., Wang, L., Zhang, Y., Han, X., Deveci, M., & Parmar, M. (2024). A review of convolutional neural networks in computer vision. *Artificial Intelligence Review*, 57(4). <https://doi.org/10.1007/s10462-024-10721-6>
- Zhou, T., Ruan, S., & Canu, S. (2020). *A review: Deep learning for medical image segmentation using multi-modality fusion.* <https://doi.org/10.1016/j.array.2019.100004>




LAMPIRAN

Lampiran 1. Data Pelatihan

A. *Avicennia Lanata*



B. *Bruguiera cylindrica*



C. Bruguiera gymnorhiza




D. Lumnitzera littorea



E. *Rhizophora apiculata*



F. *Rhizophora mucronata*




G. *Scyphiphora hydrophyllacea*



H. *Sonneratia Alba*




I. *Xylocarpus granatum*




Lampiran 2. Data Pengujian


A. *Avicennia Lanata*




B. *Bruguiera cylindrica*




C. *Bruguiera gymnorhiza*




D. *Lumnitzera liitorea*



E. *Rhizophora apiculata*



F. *Rhizophora mucronata*




G. *Scyphiphora hydrophyllacea*




H. *Sonneratia Alba*




I. *Xylocarpus granatum*




J. Multi Label




K. Posisi Objek



L. Bukan Mangrove





Lampiran 3. Code Program *Training Model*, Backend dan Frontend Aplikasi

Code *Training Model* :

<https://github.com/muhamadnursyami/training-model-faster-rcnn-mangrove>

Code Backend Aplikasi :

<https://github.com/muhamadnursyami/be-faster-rcnn-mangrove>

Code Frontend Aplikasi :

<https://github.com/muhamadnursyami/fe-reactnative-mangrove-fasterrcnn>

Lampiran 4. Pengambilan Data





